

Proyecto 0) Pasar la base a un objeto de Proceso Puntual / fecha, lugar, marca

- 1) Ver que sucede en los datos respecto a las alturas abruptas en las gráficas ¿faltan datos? sucede alrededor del 2025
- 2) ¿Por qué las métricas de S_s, S_t ?
- 3) Posible optimización de la base de los vecinos
- 4) ¿La base de vecinos es una buena covariable?
- 5) Leer y aplicar Moraga hasta K funciones

Moraga

1) Patrones de puntos espaciales

$$A \subset \mathbb{R}^2, X = \{X_1, \dots, X_{n(x)}\}, N(A) = \#(X_i \in A, \forall i)$$

$$\lambda(X) = E(\# \text{eventos por unidad de área})$$

density(): calcula el
Kernel de la intensidad
suavizada
(Por default: Gaussian)

Cada punto se lo caracteriza con una marca

Simulación: definir una ventana $\Rightarrow$ definir valores de $x, y \Rightarrow$ $\text{ppp}(x, y, \text{awin})$
 $\text{owin}(x, y)$

Alternativa: $\text{runifpoint}(n, \text{win})$

$\Rightarrow$ Definir marca: $X \leftarrow X \% \text{mark} \% 1:n\text{points}(X) / \text{mark}(X) + 1:n\text{points}(X)$

2) Simulación: dx, dy pequeñas regiones en x, y

$$\text{Intensidad: } \lambda(x) = \lim_{|dx| \rightarrow 0} \frac{E(N(dx))}{|dx|}$$

$$\lambda_2(x, y) = \lim_{\substack{|dx| \rightarrow 0 \\ |dy| \rightarrow 0}} \frac{E(N(dx)N(dy))}{|dx| |dy|}$$

$$\text{Covarianza: } \gamma(x, y) = \lambda_2(x, y) - \lambda(x)\lambda(y)$$

Un proceso puntual es estacionario: No cambian sus propiedades en la traslación

isotrópico: No cambian sus propiedades en la rotación

¿? *Estacionario: distribución conjunta de $N(A_1), \dots, N(A_n)$ es invariante a la traslación por una cantidad r arbitraria

¿? *Isotrópico: " a la rotación de un ángulo θ arbitrario

¿? *Ordenada: Si no tiene puntos encima de otro
 $\lim_{|A| \rightarrow 0} P(N(A) > 1) = 0$

Si un PP es estacionario e isotrópico, se tiene que

$$\lambda(x) = \lambda = \frac{E(N(A))}{|A|}$$

$$\lambda_2(x, y) = \lambda_2(\|x - y\|) = \lambda_2(h) \Rightarrow \gamma(x, y) = \gamma(h) = \lambda(h) - \lambda^2$$

3) Proceso de Poisson.

Con $\lambda(\cdot) \geq 0$ función de intensidad, se define:

- En $A \subset \mathbb{R}^n$, $N(A) \sim \text{Poisson}(\mu(A))$

$$\mu(A) = \int_A \lambda(x) dx \Rightarrow P(N(A)=n) = \exp(-\mu(A)) \frac{\mu(A)^n}{n!}$$

- Dado que $N(A)=n$, la locación de los n eventos forman una muestra aleatoria independiente, con función de densidad proporcional a la intensidad $\lambda(\cdot)$

¿? * Homogéneo: $\lambda(x) = \lambda, \forall x$ (Complete spatial Randomness CSR)

`rpoispp(lambda =  $\lambda$ , win)`

λ unidades por unidad de área

ojo, el código puede tomar λ de o no

¿? * Probar CSR con métodos cuantitativos (χ^2 ?) H_0 : Es CSR

con r filas y c columnas de datos no superpuestos, se define $m = rc$

$$\chi^2 = \sum_{i=1}^m \frac{(\text{observado}_i - \text{esperado})^2}{\text{esperado}} = \sum_{i=1}^m \frac{(n_i - n)^2}{n} \sim \chi_{m-1}^2$$

esperado = $\frac{n}{m}$, n observaciones

Se rechaza H_0 si $\chi^2 > \chi_{1-\alpha, m-1}^2$

Distintos H_0

two-sided H_0 : CSR vs H_1 : no CSR (regular o clustered)

regular H_0 : CSR o clustered vs H_1 : regular

clustered H_0 : CSR o regular vs H_1 : clustered

`quadrat.test(Q)`, Q : `quadratcount(X, nx, ny)`

4) Estimación de la intensidad

Si el PP es estacionario e isotrópico

$$\hat{\lambda} = \frac{n}{|A|}, \text{ con } n \text{ eventos observados en } A$$

En cambio si el PP no es estacionario ni isotrópico, se busca estimar la función de densidad por estimación de Kernell (Sabemos que la intensidad es proporcional a la densidad)

$$\lambda(x) = f(x) \int_A \lambda(u) du \quad \cdot \quad \int_A \lambda(u) du \quad \text{el número esperado de eventos en } A$$

$f(\cdot)$ función de densidad de la localización de los eventos

f se estima:

$$\hat{f}(x) = \frac{1}{n} \sum_{i=1}^n \frac{1}{h^2} K\left(\frac{x-x_i}{h}\right)$$

λ se estima:

$$\hat{\lambda}(x) = \sum_{i=1}^n \frac{1}{h^2} K\left(\frac{x-x_i}{h}\right) \quad * \quad \int_A \lambda(u) du \approx n \quad * \quad K \geq 0, \int_A K(x) dx = 1$$

* h parámetro de suavizado

ojo: Los efectos del borde tienden a distorsionar las estimaciones por Kernel cerca de la frontera se corrigen las distorsiones al dividir por:

$$p_h(x) = \int_A h^2 K\left(\frac{x-u}{h}\right) du$$

? density.ppp

Usualmente se usa Kernel Gaussiano y h , parámetro de suavizado a "sigma" = 5

* En un PPP (planar point process) con varias marcas

Si asumimos que un PPP A con marca a y otro PPP B con marca b en el mismo espacio son procesos de Poisson independientes, se tiene que

$$\underline{\lambda_A(x) = \alpha \lambda_B(x) p(x)}$$

$p(x)$ variación espacial $\hat{p} = \frac{\hat{\lambda}_A(x)}{\hat{\lambda}_B(x)}$
 α factor de ajuste

$$\hat{\lambda} = \frac{n_A}{n_B}$$

5) K-funciones

$K(S) = \lambda^{-1} E(\text{\# eventos dentro de una distancia menor a } S \text{ de un evento aleatorio})$

λ : función intensidad del PP

* En PP de Poisson y Homogéneo ubicado en una región circular C , $|C| = \pi S^2$
 $K(S) = \pi S^2$

$(K(S) > \pi S^2 \text{ clustering} \mid K(S) < \pi S^2 \text{ inhibición})$
 existe un mayor agrupamiento | menos puntos de lo esperado

* Estimar la K-función

$E(S) = E(\text{\# eventos dentro de una dist } S \text{ de un evento aleatorio})$
 $= \lambda K(S)$

Se estima: $\tilde{E}(S) = \frac{1}{n} \sum_{i=1}^n \sum_{j \neq i} \mathbb{1}(d_{ij} \leq S)$ ¿Qué sucede con los eventos cerca de la frontera?

$$\tilde{E}(S) = \frac{1}{n} \sum_{i=1}^n \sum_{j \neq i} w_{ij} \mathbb{1}(d_{ij} \leq S)$$

$w_{ij} \approx \frac{1}{\text{proporción de la circunferencia } \cap A(x_i, d_{ij})}$

Si el proceso es homogéneo ($\hat{\lambda} = \frac{n}{|A|}$)

$$\hat{K}(S) = \frac{\tilde{E}(S)}{\hat{\lambda}} = \frac{|A|}{n^2} \sum_{i=1}^n \sum_{j \neq i} w_{ij} \mathbb{1}(d_{ij} \leq S)$$

Kest estima el K de un ppp X Ej $X \leftarrow rpoispp(\text{lambdas} = 100)$

$K \leftarrow Kest(X)$ # usa 3 métodos distintos
 $\leftarrow Kest(X)$ para corregir el efecto del borde

¿? Graficar K y si es

y la confianza $\text{envelope}(X, Kest, \text{num})$
 $\text{plot}(l)$

Escenario A: Agrupamiento (Clustering)

- Qué significa: Los puntos tienden a atraerse o a aparecer juntos debido a algún factor común (por ejemplo, focos de contagio de una enfermedad o la ubicación de recursos compartidos).
- En el gráfico: Tu curva calculada ($\hat{K}$) queda por encima de la línea teórica. Significa que encontraste más vecinos a esa distancia r de lo que dictaría el azar.

Escenario B: Regularidad o Repulsión (Inhibition)

- Qué significa: Los puntos guardan una distancia mínima entre sí, usualmente por competencia o planificación (por ejemplo, los nidos de aves que defienden su territorio, o la distribución de postes de luz).
- En el gráfico: Tu curva calculada ($\hat{K}$) queda por debajo de la línea teórica. Significa que encontraste menos vecinos alrededor de los puntos (más espacio vacío) de lo esperado por el azar.

Escenario C: Aleatoriedad Completa (CSR)

- Qué significa: Los puntos ocurren de manera homogénea e independiente. Que haya un punto en un lugar no te da ninguna pista de si habrá otro cerca o lejos.
- En el gráfico: Tu curva calculada se pega casi perfectamente a la línea teórica (como en el gráfico de tu simulación).

* Modelo 1 vs Modelo

intercambiar las variables temporales y volver a comparar

Sim cluster

1) Objetivo: selección del modelo

- Análisis de sensibilidad: Probar hasta que falle

Ej: • % Pérdida de datos $\Rightarrow$ • Umbral
• Tamaño de la grilla • falla el cluster ✓

Probar:

Modelo lineal (en función tiempo o espacio)
est. demandas

Arima

r-largot vs Excedencias

estimar los parámetros

métricas para ver cuál es el mejor

Comentar porque
r-largot falla / Comparar

* Revisar el EVGAM

Porque no funcionaria modelarlo como una serie temporal

* Trabajar con todas las magnitudes o solo con las excepciones.

Se debería trabajar con todas las magnitudes, caso contrario se rompe la regularidad del intervalo

Arima asume los errores se distribuyen con un comportamiento normal y busca modelar la media del proceso
t-student

¿Un Garch podría servir? Podría servir para capturar la volatilidad de la variante, pero falla al trabajar con intervalos regulares y discretos, lo que agregaría o lo que sesgaría el modelo

Posibles soluciones

1) Usar Block maxima (r-largest)

¿Podería con modelos de ST en cada bloque?
¿Cómo uniríamos luego cada serie?

2) Modelar conteos (INGARCH o regresión de Poisson)

Ojo las magnitudes que superen el umbral igual de lo, debe modelar con GPD.

Interesante *

3) Procesos de Puntos Marcados

* Ver mapa tránsito / Quinche

* Mapas de punto homicidios / Gradiente de color

Homicidios filtrar a partir del corte abrupto

Fundamentos e intuición de los Procesos Puntuales (Observamos una realización finita de eventos)

Geostatística

- lattice (área) individual
- Observaciones a lugares específicos (muestreo para llenar huecos?) Krigging
- Procesos Puntuales: longitud y latitud, fecha y hora, etc.

¿Dónde se concentra el riesgo?

¿Queremos identificar nuevas zonas de riesgo? ¿A futuro?

* En la definición de un Proceso Puntual es muy importante el término de ventana (región donde el proceso puede ser observado)

¿Cómo se toma el borde de la ventana?

* Un PP es una V.A. (ver sus propiedades)

* Intensidad de un PP $\lambda(s)$, $s \in W$, se define

$$E(N(ds)) \approx \lambda(s)$$

* La intensidad NO es simplemente "donde están los puntos"

* Propiedades de segundo orden: Dependencia entre pares de eventos

* CSR: Complete Spatial Randomness ($\lambda(s) = \lambda, \forall s \in W$)

* Puntos cercanos no implican interacción, se debería ver la heterogeneidad espacial

Probar los 3 tipos de procesos puntuales (cambiar parámetros)

SpatsStat

Ver una región de estudio y por qué esa

- Calcular $N(W)$ y conteos por subregión quadrant test (10,10)

Segunda tarea: Graficar el conjunto de datos que trabajaremos
Homicidios

Proceso Puntual como medida

$$N(A) = \# \{x_i \in A\}, A \subset W$$

$$N(A) = \sum_i 1_{\{x_i \in A\}}$$

$$PP = \{N(A) : A \subset W\}$$

* Proceso de Poisson Homogéneo

$W \subset \mathbb{R}^2$ acotada, $\lambda > 0$

Un PP X_n en W con intensidad λ, λ_i

a) $\forall A \subset W$ medible

$$N(A) \sim \text{Poisson}(\lambda|A|) \quad ; |A| \text{ área de } A$$

b) $\{A_i\}_{i=1}^n \subset \mathcal{P}(W)$ disjuntos

$\{N(A_i)\}_{i=1}^n$ son v.a. independientes

$$\lambda = \frac{E(N(A))}{|A|} \quad \# \text{ número de eventos en la región } A$$

* Distribución del # total de puntos

X_n proc. Poisson Hom en W

$$N(W) \sim \text{Poisson}(\lambda|W|)$$

$$P(N(W)=n) = \frac{(\lambda|W|)^n}{n!} e^{-\lambda|W|}$$

Definir una región de trabajo No Quito

* Independencia de regiones ligadas

$$A \cap B = \emptyset \Rightarrow N(A) \perp N(B)$$

ojo

$$N(A \cup B) = N(A) + N(B) \sim \text{Poisson}(\lambda(|A| + |B|)) = \text{Poisson}(\lambda|A \cup B|)$$

* Distribución condicional de las observaciones

X Pro Poisson Hom en W con mte λ . Condicionalemente a que $N(W) = n$
las observaciones de los puntos son ind y uni en W

$$X_1, \dots, X_n | N(W) = n \sim \text{Unit}(W)$$

Definir la base de datos como un PPP

Definir la red (Administrativa)

Estimar la intensidad homogénea