



ESCUELA POLITÉCNICA NACIONAL

FACULTAD DE CIENCIAS

MODELAMIENTO DE DEPENDENCIA ESPACIAL Y CORRELACIÓN ENTRE RÉPLICAS EN PATRONES PUNTUALES MARCADOS

PRUEBAS DE BONDAD DE AJUSTE

**TRABAJO DE INTEGRACIÓN CURRICULAR PRESENTADO COMO
REQUISITO PARA LA OBTENCIÓN DEL TÍTULO DE TÍTULO
PROFESIONAL A OBTENER**

DANIEL SEBASTIÁN LARA DEL SALTO

daniel.lara02@epn.edu.ec

DIRECTOR: YANDIRA DENISSE CUVERO CALERO

yandira.cuvero@epn.edu.ec

DMQ, MES AÑO

CERTIFICACIONES

Yo, DANIEL SEBASTIÁN LARA DEL SALTO, declaro que el trabajo de integración curricular aquí descrito es de mi autoría; que no ha sido previamente presentado para ningún grado o calificación profesional; y, que he consultado las referencias bibliográficas que se incluyen en este documento.

Daniel Sebastián Lara Del Salto

Certifico que el presente trabajo de integración curricular fue desarrollado por Daniel Sebastián Lara Del Salto, bajo mi supervisión.

Yandira Denisse Cuvero Calero
DIRECTOR

DECLARACIÓN DE AUTORÍA

A través de la presente declaración, afirmamos que el trabajo de integración curricular aquí descrito, así como el(los) producto(s) resultante(s) del mismo, es(son) público(s) y estará(n) a disposición de la comunidad a través del repositorio institucional de la Escuela Politécnica Nacional; sin embargo, la titularidad de los derechos patrimoniales nos corresponde a los autores que hemos contribuido en el desarrollo del presente trabajo; observando para el efecto las disposiciones establecidas por el órgano competente en propiedad intelectual, la normativa interna y demás normas.

Daniel Sebastián Lara Del Salto

Yandira Denisse Cuvero Calero

RESUMEN

(Máximo 250 palabras)

Palabras clave: palabra1, palabra2, palabra3,..., palabra6.

ABSTRACT

(Máximo 250 palabras)

Keywords: palabra1, palabra2, palabra3, . . . , palabra6.

Índice general

1. Descripción del componente desarrollado	1
1.1. Objetivo general	1
1.2. Objetivos específicos	1
1.3. Alcance	2
1.4. Marco teórico	2
2. Metodología	8
3. Resultados, conclusiones y recomendaciones	17
3.1. Resultados	17
3.2. Conclusiones y recomendaciones	17
A. Título anexo	18
Bibliografía	19

Índice de figuras

2.1. Comparación del conteo de eventos sísmicos antes y después del filtrado por magnitud de completitud. No es que hubiera menos sismos, sino que actualmente se registran con mayor precisión instrumental.	9
2.2. Relación de Gutenberg-Richter: $\log_{10}(N) = a - bM$ para el catálogo de eventos sísmicos filtrado por magnitud de completitud.	10
2.3. Función K de Ripley para el catálogo de eventos sísmicos. Para un patrón de clustering, se debe cumplir que $K(r) > \pi r^2$, lo cual se evidencia estadísticamente también con el valor $p=0.01$ por Envoltentes de Monte Carlo que no cumple con CSR (H_0).	11
2.4. Distribución empírica de la distancia espacio-temporal normalizada en escala logarítmica ($\log_{10}(\eta)$) obtenida mediante el algoritmo de Zaliapin.	14
2.5. Mezcla de dos distribuciones normales ajustadas a cada moda y miden el comportamiento de las poblaciones dependientes (cola izquierda) y independientes (cola derecha) y el umbral de separación entre las poblaciones.	15

Capítulo 1

Descripción del componente desarrollado

Se sugiere que el documento de Trabajo de Integración Curricular tenga una extensión total de entre 30 y 50 hojas, sin considerar los anexos.

Describir de forma simple el componente que fue desarrollado.

1.1. Objetivo general

Estudiar las propiedades, características y modelos estadísticos asociados a procesos puntuales marcados.

1.2. Objetivos específicos

1. OE1
2. OE2
3. OE3
4. OE4: Proponer dos objetivos específicos en base al estudio de valores extremos.

1.3. Alcance

Describir el alcance del componente de acuerdo a los datos y la ventana de datos y definir las unidades de las magnitudes de importancia.

Declustering, lograrlooooo

1.4. Marco teórico

1. Procesos Puntuales

a) Procesos Puntuales Marcados

Definición: Sea $(A, \mathcal{B}(A))$ un espacio medible, donde:

- A es un conjunto no vacío, y
- $\mathcal{B}(A)$ es la σ -álgebra de Borel del conjunto A .

Un Proceso puntual es una medida aleatoria de conteo N definida sobre $(A, \mathcal{B}(A))$.

$$N : \mathcal{B}(A) \longrightarrow \mathbb{N}_0 \cup \{+\infty\}$$

$$B \longmapsto N(B) = \sum_{i=1}^{\infty} \mathbf{1}(x_i \in B)$$

Entonces un Proceso Puntual Marcado es un Proceso Puntual N definido sobre $(A, \mathcal{B}(A))$ y un conjunto de marcas M con σ -álgebra $\mathcal{B}(M)$, tal que N es una medida aleatoria de conteo definida sobre $(A \times M, \mathcal{B}(A) \otimes \mathcal{B}(M))$.

$$N : \mathcal{B}(A \times M) \longrightarrow \mathbb{N}_0 \cup \{+\infty\}$$

$$X \times Y \longmapsto N(X \times Y) = \sum_{i=1}^{\infty} \mathbf{1}(x_i \in X, m_i \in Y)$$

Con $N(X \times Y) < \infty$ para todo $X \in \mathcal{B}(A)$ y $Y \in \mathcal{B}(M)$. [3]

b) Propiedades de un Proceso Puntual Marcado

- **Medida de Intensidad de un Proceso Puntual Marcado.**

Sea $\Phi = \{(X_i, M_i)\}_{i=1}^{\infty}$ un Proceso Puntual Marcado en $S \times M$, donde:

- $X_i \in S$ es la ventana de estudio del conjunto de eventos S ,
- $M_i \in M$ es la marca asociada al evento (X_i) del conjunto de marcas M .

La medida de intensidad de Φ es el primer momento de la medida aleatoria de conteo N definida sobre $(S \times M, \mathcal{B}(S) \otimes \mathcal{B}(M))$, es decir:

$$\Lambda(A \times C) = \mathbb{E}[N(A \times C)]$$

Con $A \in \mathcal{B}(S)$ y $C \in \mathcal{B}(M)$. [3]

■ **Medida de Covarianza de un Proceso Puntual Marcado**

(γ) Sea $\Phi = \{(X_i, M_i)\}_{i=1}^{\infty}$ un Proceso Puntual Marcado en $S \times M$, donde S es la ventana de estudio y M es el espacio de marcas asociadas a los eventos de S . La medida de covarianza del proceso caracteriza las propiedades de segundo orden, cuantificando la dependencia conjunta entre un par de eventos y marcas a lo largo de la ventana de estudio. Sean $A_1, A_2 \in \mathcal{B}(S)$ y $C_1, C_2 \in \mathcal{B}(M)$, la medida de covarianza se define como:

$$\gamma(A_1 \times C_1, A_2 \times C_2) = Cov(N(A_1 \times C_1), N(A_2 \times C_2))$$

Donde N es la función de conteo del Proceso Puntual Marcado Φ . [3]

- **Convergencia débil de un Proceso Puntual** Se dice que una sucesión de Procesos Puntuales $\{N_n\}_{n \in \mathbb{N}}$ en el mismo espacio medible E converge débilmente a un Proceso Puntual N en E si para una colección de subconjuntos acotados $\{A_j\}_{j=1}^k \subset E$. Si se cumple que:

$$(N_n(A_1), \dots, N_n(A_k)) \xrightarrow{d} (N(A_1), \dots, N(A_k)) \forall n \in \mathbb{N} \quad \text{y}$$

$$\Pr(N(\partial A_i) = 0) = 1, \quad i = 1, \dots, k, \quad k \geq 1$$

Con ∂A_i la frontera de A_i en el espacio medible E . Con relación a esto último indicaría que no existen eventos en la

frontera del conjunto A_i [4]

c) **Procesos de Poisson Definición:** Un Proceso Puntual de Poisson es un Proceso Puntual N definido sobre un espacio medible E , tal que:

- Para cualquier conjunto acotado $A \in E$, $N(A)$ sigue una distribución de Poisson con parámetro $\Lambda(A)$.
- Para cualquier colección finita de conjuntos acotados disjuntos $\{A_j\}_{j=1}^k \subset E$, las variables aleatorias $N(A_1), \dots, N(A_k)$ son independientes entre ellas.

[3]

d) **Complete Spatial Randomness (CSR)** El fenómeno de Complete Spatial Randomness (CSR) hace referencia a un patrón puntual que es completamente aleatorio en el espacio de estudio, es decir, que el proceso es sinónimo de un proceso de Poisson homogéneo, donde la intensidad del proceso es constante en todo el espacio de estudio y los eventos son independientes entre sí. Este fenómeno se lo mencionará con la siguiente hipótesis nula: H_0 : CSR, y se lo contrastará con la hipótesis alternativa H_1 : No CSR, donde el patrón puntual es no aleatorio y presenta un comportamiento de clusterización, inhibición, intensidad no constante, anisotropía o efectos de borde o errores de medición.

[5]

e) *Relación del conteo de eventos bajo ciertas condiciones sigue una distribución de Poisson*

2. Teoría de Valores Extremos

La teoría de valores extremos es una rama de la estadística enfocada en analizar eventos en los datos concentrados en las colas de su distribución. Esta teoría prevé un camino para el entendimiento y modelamiento de los comportamientos de los valores que superen un cierto umbral crítico ó en los máximos obtenidos en períodos de interés.

Estableciendo una analogía con el Teorema Central del Límite, la teoría de valores extremos determina un marco teórico para el modelamiento de los datos extremos o máximos de una muestra alea-

toria. Con esto en cuenta, el presente trabajo hará hincapié en dos enfoques dentro de la Teoría de Valores Extremos: el enfoque de máximos por bloques; y, el enfoque de valores por encima de un umbral. [1]

- **Enfoque de Máximos por Bloques: Distribución Generalizada de Valores Extremos** Este enfoque consiste en dividir la serie de datos en bloques contiguos de igual tamaño para extraer el valor máximo de la base de cada uno. La colección de máximos se ajusta a una Distribución de Valores Extremos Generalizada (GEV); sin embargo, presenta el problema de que, si una región de continuos contiene múltiples eventos extremos importantes, solo el mayor es considerado, descartando de esta manera información potencialmente valiosa de los demás datos.
- **Enfoque de Umbral: Picos sobre el Umbral** Este enfoque consiste en fijar un umbral crítico u y seleccionar únicamente las observaciones que lo superan. Las magnitudes de estas excepciones se modelan mediante una Distribución Pareto Generalizada (GPD) al momento de considerar el umbral u acercándose al infinito, lo que permite aprovechar de mejor manera todos los datos extremos disponibles en toda serie de datos.

[2]

Las funciones de Distribución Generalizada de Valores Extremos y Generalizada de Pareto, respectivamente son:

- Distribución Generalizada de Valores Extremos:

$$G(x; \mu, \sigma, \xi) = \exp \left\{ - \left[1 + \xi \left(\frac{x - \mu}{\sigma} \right) \right]^{-1/\xi} \right\} \quad (1.1)$$

Donde:

- $\mu \in \mathbb{R}$ es el parámetro de localización,
- $\sigma > 0$ es el parámetro de escala, y
- $\xi \in \mathbb{R}$ es el parámetro de forma.

- Distribución Generalizada de Pareto:

$$H(y; \tilde{\sigma}, \xi) = 1 - \left(1 + \frac{\xi y}{\tilde{\sigma}}\right)_+^{-1/\xi} \quad (1.2)$$

Donde:

- $\tilde{\sigma} > 0$ es el parámetro de escala, y
- $\xi \in \mathbb{R}$ es el parámetro de forma.

[2]

Los valores de los parámetros σ y $\hat{\sigma}$ describen la escala de los datos extremos en los enfoques de máximos por bloques y por umbrales, respectivamente. Por otro lado, la forma de los datos extremos (ver la forma de las colas de las distribuciones) está condicionada por el parámetro ξ en ambos enfoques.

3. Modelamiento de Valores Extremos como Procesos Puntuales Marcados: EVGAM con familia de distribución GPD

Dentro de los dos enfoques en la Teoría de Valores Extremos el mejor método para aprovechar la información de los datos extremos que superen un umbral crítico, es el método de Umbral (POT), ya que permite modelar los datos extremos disponibles en la serie de datos. No obstante, los procesos generadores de datos extremos frecuentemente exhiben un comportamiento no estacionario, donde los parámetros de las distribuciones límite varían en función de variables indexadoras o covariables externas. Por lo tanto, para lograr capturar estos efectos y variaciones en los parámetros de la distribución, se propone el modelamiento del Proceso Puntual Marcado de los datos extremos mediante un Modelo Aditivo Generalizado.

- Modelo Aditivo Generalizado:** Este tipo de modelo se inspira de los Modelos Lineales Generalizados (GLM), pero permite que los parámetros de la distribución de probabilidad de la variable respuesta dependan por una función enlace a una combinación lineal de funciones suaves que dependen de las covariables con el objetivo que se cumplan las restricciones de los parámetros de la distribución y se tenga mayor poder predictivo.

- b) **Representación por Bases:** Al ser una combinación lineal de funciones suaves, estas funciones pueden representarse mediante una combinación lineal de bases.

$$\eta_*(x) = \beta_0 + \sum_{k=1}^K \sum_{d=1}^{D_k} \beta_{k,d} b_{k,d}(x)$$

Donde $\eta_*(x)$ es el predictor aditivo asociado al parámetro $\mu(x)$ que depende de un vector de covariables de dimensión K, y para cada componente del vector de covariables se considera una base de funciones predefinidas y conocidas de dimensión D_k .

- c) **Caracterización del Proceso Puntual de Excedencias**

- d) **Máxima Verosimilitud Penalizada:**

[6]

Observación: Para esta sección se sugiere un máximo del 20 % de la extensión del documento, de esta manera, se dará mayor énfasis al trabajo realizado propiamente por el estudiante.

Capítulo 2


Metodología

Este trabajo busca describir el comportamiento de los eventos sísmicos extremos en relación con variables geográficas y geológicas durante un periodo delimitado. El desarrollo del componente se enmarca en un enfoque cuantitativo, basado en el análisis numérico de registros sísmicos y la estimación matemática de los parámetros de las distribuciones probabilísticas que mejor representen los datos empíricos. Para ello, el estudio se fundamenta en la Distribución Generalizada de Pareto (GPD). La selección de este modelo se sustenta en la literatura científica, la cual demuestra su eficacia para el análisis de valores extremos mediante el enfoque de Picos sobre el Umbral (POT), destacando su eficiencia en el uso de datos y su capacidad para modelar directamente las excedencias sobre un umbral físico interpretable.

El método empleado es de tipo hipotético-deductivo. Se parte de la hipótesis central de que la energía sísmica superior a un umbral base puede ser modelada mediante la distribución GPD, cuyos parámetros fluctúan dinámicamente en función de covariables físicas y espaciotemporales. A partir de esta premisa, se deducen implicaciones estadísticas y se ejecutan pruebas empíricas para validar o refutar la hipótesis, evaluando el ajuste de la distribución al someterla a distintos escenarios. En consecuencia, la investigación presenta un diseño explicativo y correlacional, ya que busca evaluar y cuantificar cómo la interacción de las variables físicas y espaciales determinan el comportamiento del parámetro de es-

cala (σ) en el modelo de excedencias.

Un primer paso en el desarrollo del componente consistió en la mejora del catálogo de eventos sísmicos, fue necesario realizar una limpieza de datos en función al tipo de magnitud registrada y sus variantes ; se tomó el tipo de magnitud Momento (M_w), pues, es el tipo de magnitud que nos permite medir el tamaño físico del sismo en función de la energía liberada. También datos se dividirán datos incompletos, y de ser el caso, determinar la muestra de eventos en función de la calidad de los datos registrados. Se nota que existe un aumento en el número de eventos sísmicos registrados a lo largo del tiempo, sin embargo existe un periodo de tiempo con datos faltantes, por ende se trabajará con los datos siguientes al año 1984, ya que a partir de este año se cuenta con un registro más confiable y consistente.



(a) Catálogo original.



(b) Eventos tras filtrado por M_c y por tiempo.

Figura 2.1: Comparación del conteo de eventos sísmicos antes y después del filtrado por magnitud de completitud. No es que hubiera menos sismos, sino que actualmente se registran con mayor precisión instrumental.

El segundo paso consistió en tener un catálogo fiable y mayormente completo según la Ley de Gutenberg-Richter, la cual describe la relación entre la magnitud y la frecuencia de los sismos, otorgándonos la ventaja de encontrar una magnitud mínima de completitud a partir del cual se empieza a considerar una relación log-lineal entre la frecuencia y la magnitud. Como resultado de este análisis, se indentificó un umbral mínimo de mangitud de $M_c = 5,4$, el cual fue utilizado para filtrar los eventos sísmicos y sea consistente la Ley de Gutenberg-Richter.




Figura 2.2: Relación de Gutenberg-Richter: $\log_{10}(N) = a - bM$ para el catálogo de eventos sísmicos filtrado por magnitud de completitud.

Ahora, con un catálogo completo y ordenado, se debe hacer un diagnóstico acerca de sus dependencias espacio-temporales, se busca evaluar si dentro de la componente espacial existe la posibilidad de ver CSR clustering e inhibición, se espera que se evidencie un patrón de clustering, pues al estar cerca de fallas geológicas los inicios del sismo se concentran en ciertas zonas geográficas, generando un agrupamiento de eventos. Una manera sencilla de evaluar esta dependencia espacial es mediante la función K de Ripley, la cual permitirá determinar si existe un patrón en específico.




Figura 2.3: Función K de Ripley para el catálogo de eventos sísmicos. Para un patrón de clustering, se debe cumplir que $K(r) > \pi r^2$, lo cual se evidencia estadísticamente también con el valor $p=0.01$ por Envolveres de Monte Carlo que no cumple con CSR (H_0).

Por lo tanto, en la componente espacial hay certeza de una clusterización de eventos, era lo esperado. Ahora, en cuanto a la dependencia temporal, se busca evaluar si existe un patrón de CSR principalmente; o, secundariamente inhibición o clustering de eventos en el tiempo. Se espera en sismicidad natural, lo habitual. Antes de limpiar el catálogo de datos, es conocido que surge un agrupamiento de eventos sísmicos provocados por las secuencias de réplicas y no por un patrón de CSR, en cuyo caso será necesario aplicar su desclusterización filtrando los eventos que provoquen réplicas en función del intervalo de tiempo entre estos. Previo a la desclusterización, el análisis de la dependencia temporal se consideró los valores "p" de las pruebas de Ljung-Box y de Rachas. La primera analiza la autocorrelación en los retardos temporales; mientras que la segunda (test de Rachas) detecta desviaciones de la aleatoriedad de eventos sísmicos en el tiempo mediante la binarización de los intervalos entre eventos, clasificándolos en función de, si superan o no la mediana muestral; y, la cantidad de rachas para comparar con lo esperado bajo aleatoriedad. Entonces, si se encuentra pocas rachas que cumplan el factor, significa que hubo mayor cantidad de agrupamientos de eventos sísmicos, es decir de réplicas; en otras palabras, es evidente que la actividad sísmica está

sujeta a una dependencia temporal. De existir una importante cantidad de rachas, es evidente que se estaría frente a un patrón con mayor alternancia de estados provocado posiblemente por inhibición o regularidad de eventos.

Una vez aplicado el algoritmo de desclusterización se garantiza que:

- Si $s \leq t$ entonces $N_s \leq N_t$
- Para todo $n > 0$ y la sucesión creciente de tiempos $\{t_i\}_{i=1}^n$ se cumple que $N_{t_1}, N_{t_2} - N_{t_1}, \dots, N_{t_n} - N_{t_{n-1}}$ son independientes.

En el primer punto, los sismos se cuentan de manera acumulativa en el tiempo, y para el segundo punto, la desclusterización elimina las replicas y secuencias dependientes asociadas a los eventos principales en un bloque de tiempo, la ocurrencia de sismos en el intervalo no condiciona ni aporta información sobre su conteo en el siguiente bloque disjunto, garantizando que los incrementos estocásticos en intervalos de tiempo consecutivos sean independientes.

Prueba de Ljung-Box		Prueba de Rachas	
Estadístico	1.2641	Estadístico	-2,6958
p-valor	0.2609	p-valor	0.007
<i>Existe independencia temporal</i>		<i>Existe dependencia temporal</i>	

Cuadro 2.1: Diagnóstico de dependencia temporal antes de la desclusterización entre eventos sísmicos.

A continuación se realizará la desclusterización de los eventos sísmicos como buena práctica para dar más seguridad al postulado de independencia de estos eventos: $N_{t_1}, N_{t_2} - N_{t_1}, \dots, N_{t_n} - N_{t_{n-1}}$.

El algoritmo de desclusterización utilizado es el propuesto por Baiesi y Paczuki, 2004, el cual se basa en reconocer en una red de fallas geológicas, los sismos más cercanos a un evento principal, para seguidamente poder filtrarlos en función de la magnitud del evento principal y de la distancia espacial y temporal de los eventos asociados. La idea es que un evento principal pueda generar un conjunto de eventos dependientes en una ventana de tiempo y espacio, los cuales deberán ser eliminados

del catálogo de eventos sísmicos para garantizar la independencia de los incrementos estocásticos.

Entonces se deberá calcular los vecinos más cercanos en función de la magnitud de cada evento principal. Para ello la idea es calcular una distancia de interacción entre eventos sísmicos, definida por:

$$\eta_{ij} = \begin{cases} (r_{ij})^{d_f} 10^{-b(m_i)}(t_j - t_i), & \text{si } t_j > t_i, \\ \infty, & \text{si } t_j \leq t_i, \end{cases} \quad (2.1)$$

Notemos varios puntos de la ecuación anterior:

- r_{ij} es la distancia espacial entre los epicentros de los eventos i y j .
- d_f es la dimensión fractal del epicentro en la red de fallas geológicas, la cual se estima en $d_f = 1,6$ para la región de estudio. Mide en promedio que tanto decae la densidad de las réplicas luego del evento
- b es el parámetro de la Ley de Gutenberg-Richter, el $b \sim 1$ para la región de estudio. Mide la relación entre la magnitud y la frecuencia de los eventos sísmicos.
- m_i es la magnitud del evento principal i que debe superar por lo anterior dicho a m_c .
- $t_j - t_i$ es el intervalo de tiempo entre los eventos i y j , el cual debe ser positivo para que el evento j pueda ser considerado como una réplica del evento i .
- $10^{-b(m_i)}$ ayudará a establecer que a grandes magnitudes la distancia η_{ij} deberá ser más cercana.

Y para cada evento j se buscará su padre i que minimice la distancia de interacción η_{ij} , es decir, el evento principal más cercano en el tiempo y espacio. Como siguiente paso, se deberá calcular las interacciones temporales y espaciales, normalizadas por un factor en función de la magnitud del evento principal:

$$T_{ij} = 10^{-qb(m_i)}(t_j - t_i), \quad R_{ij} = 10^{-pb(m_i)}r_{ij}^{d_f}, \quad (2.2)$$

con $p + q = 1$, y $p, q \in [0, 1]$. En este caso se tomará $p = 0,5$ y $q = 0,5$, para dar el mismo peso a la interacción temporal y espacial.

Con las ecuaciones de interacción temporal y espacial, se puede definir una interacción η_j , el cual se define en función de $\log_{10}(T_j)$ y $\log_{10}(R_j)$, y se puede calcular como:

$$\log_{10}(\eta_j) = \log_{10}(T_j) + \log_{10}(R_j) \quad (2.3)$$

Notemos que el valor de η_j mide la distancia entre los eventos j y sus padres, y medirá la dependencia temporal y espacial entre estos. Si $T_j \rightarrow 0$ y/o $R_j \rightarrow 0$, entonces $\eta_j \rightarrow 0$, lo cual significa que el evento j es una réplica del sismo padre. Por otro lado, si $\eta_j \rightarrow \infty$, entonces el evento j es independiente del evento principal porque estará más alejado en el tiempo o espacio.

Además, esta interacción con datos sísmicos generará una distribución bimodal, pues, presentará dos modas por la mezcla de dos comportamientos, en este caso; una rama se caracterizará por los eventos que estén elajados (lejanía temporal o espacial), en cambio la otra rama tendrá los sismos más cercanos al evento principal, clasificándolos como dependientes.




Figura 2.4: Distribución empírica de la distancia espacio-temporal normalizada en escala logarítmica ($\log_{10}(\eta)$) obtenida mediante el algoritmo de Zaliapin.

Como se mencionó y se observa en el gráfico anterior, el histograma de los valores $\log_{10}(\eta)$ presenta dos comportamientos con modas diferentes. La rama izquierda, con valores mucho más negativos, concentra los eventos dependientes; en ella, la proximidad espacial y temporal respecto a un evento principal es alta ($\eta_j = T_j \cdot R_j \approx 0$). Por otro lado, la rama derecha, con una concentración alrededor de -2 , agrupa los eventos independientes, ya que los valores de η_j se alejan de 0 al no mostrar cercanía espacial ni temporal respecto al evento principal.

Para separar ambas ramas, existen varios criterios: (i) tomar el mínimo local de la densidad empírica en la zona de transición entre ambas modas como umbral; o (ii) ajustar una mezcla de dos distribuciones normales a los valores de $\log_{10}(\eta)$ y tomar como umbral el punto de intersección entre ambas densidades ajustadas. En este trabajo se optó por el criterio analítico de estimar una mixtura de distribuciones normales. Para lograrlo se empleó el algoritmo Expectación–Maximización (EM) para mixtura de normales (Benaglia, T., Chauveau, D., Hunter, D. R., & Young, D. S. (2009)) implementado en el paquete **mixtools** de R. Una vez aplicado y obtenidos los parámetros necesarios: vector de pesos λ vector de medias μ , vector de desviaciones estándar σ . El umbral η_0 se define como el valor de $\log_{10}(\eta_j)$ donde las dos densidades ajustadas se intersecan, lo que corresponde al punto de separación entre los eventos dependientes e independientes.




Figura 2.5: Mezcla de dos distribuciones normales ajustadas a cada moda y miden el comportamiento de las poblaciones dependientes (cola izquierda) y independientes (cola derecha) y el umbral de separación entre las poblaciones.

El umbral se obtuvo de resolver $f(x) = 0$ con f una función auxiliar, definida como:

$$f(x) = \lambda_1 f_{\mu_1, \sigma_1}(x) - \lambda_2 f_{\mu_2, \sigma_2}(x), \quad x \in [\text{mín}(\mu_1, \mu_2), \text{máx}(\mu_1, \mu_2)]. \quad (2.4)$$

Donde, f_{μ_i, σ_i} es la densidad normal de cada población i . Con el resultado de que nuestro umbral $\eta_0 \approx -3,239$.

Capítulo 3

Resultados, conclusiones y recomendaciones

3.1. Resultados

Exponer los resultados obtenidos.

$$x^2 + y^2 = z^2 \quad (3.1)$$

3.2. Conclusiones y recomendaciones

Presenta lo novedoso del trabajo de integración curricular, así como el cumplimiento o no de lo propuesto en los objetivos. En el caso en que no se cumpla uno o varios objetivos, y no se logren los resultados esperados, se propone una posible respuesta que explique por qué sucedió esto o las falencias de la planteado.

Indicar las recomendaciones formuladas a partir del desarrollo de este trabajo de integración curricular.

Capítulo A

Título anexo

En caso necesario, el documento escrito deberá incluir los anexos y secciones que incorporan información que sea relevante, pero que, por su extensión, no pueden ser incorporadas directamente en ninguna de las secciones anteriores.

Referencias bibliográficas

- [1] Certificate in Quantitative Finance (CQF). What is Extreme Value Theory? <https://www.cqf.com/blog/quant-finance-101/what-is-extreme-value-theory>, 2024. Accedido en julio de 2026. Análisis introductorio sobre el enfoque Block Maxima y Peaks Over Threshold (POT).
- [2] Stuart Coles. *An Introduction to Statistical Modeling of Extreme Values*. Springer Science & Business Media, London, 2001. El Capítulo 3 sustenta la GEVD y el Teorema de Fisher-Tippett-Gnedenko. El Capítulo 4 detalla el método POT y la GPD.
- [3] Daryl J. Daley and David Vere-Jones. *An Introduction to the Theory of Point Processes: Volume I: Elementary Theory and Methods*. Springer Science & Business Media, 2003.
- [4] Daryl J. Daley and David Vere-Jones. *An Introduction to the Theory of Point Processes: Volume II: General Theory and Structure*. Springer Science & Business Media, New York, 2nd edition, 2008.
- [5] Paula Moraga. *Spatial Statistics for Data Science: Theory and Applications with R*. CRC Press, Boca Raton, 2023. El Capítulo sobre Complete Spatial Randomness detalla las pruebas de hipótesis y funciones diagnósticas para el modelamiento de patrones puntuales.
- [6] Benjamin D. Youngman. evgam: An R package for generalized additive extreme value models. *Journal of Statistical Software*, 103(3):1–26, July 2022.