ESCUELA POLITÉCNICA NACIONAL

FACULTAD DE CIENCIAS

MODELAMIENTO DE DEPENDENCIA ESPACIAL Y CORRELACIÓN ENTRE RÉPLICAS EN PATRONES PUNTUALES MARCADOS

PRUEBAS DE BONDAD DE AJUSTE

TRABAJO DE INTEGRACIÓN CURRICULAR PRESENTADO COMO REQUISITO PARA LA OBTENCIÓN DEL TÍTULO DE TÍTULO PROFESIONAL A OBTENER

DANIEL SEBASTIÁN LARA DEL SALTO

daniel.lara02@epn.edu.ec

DIRECTOR: YANDIRA DENISSE CUVERO CALERO

yandira.cuvero@epn.edu.ec

DMQ, ENERO 2027

CERTIFICACIONES

Yo, DANIEL SEBASTIÁN LARA DEL SALTO, declaro que el trabajo de integración curricular aquí descrito es de mi autoría; que no ha sido previamente presentado para ningún grado o calificación profesional; y, que he consultado las referencias bibliográficas que se incluyen en este documento.

Daniel Sebastián Lara Del Salto

Certifico que el presente trabajo de integración curricular fue desarrollado por Daniel Sebastián Lara Del Salto, bajo mi supervisión.

Yandira Denisse Cuvero Calero

DIRECTOR

DECLARACIÓN DE AUTORÍA

A través de la presente declaración, afirmamos que el trabajo de integración curricular aquí descrito, así como el(los) producto(s) resultante(s) del mismo, es(son) público(s) y estará(n) a disposición de la comunidad a través del repositorio institucional de la Escuela Politécnica Nacional; sin embargo, la titularidad de los derechos patrimoniales nos corresponde a los autores que hemos contribuido en el desarrollo del presente trabajo; observando para el efecto las disposiciones establecidas por el órgano competente en propiedad intelectual, la normativa interna y demás normas.

Daniel Sebastián Lara Del Salto

Yandira Denisse Cuvero Calero

RESUMEN

(Máximo 250 palabras)

Palabras clave: palabra1, palabra2, palabra3,. . ., palabra6.

ABSTRACT

(Máximo 250 palabras)

Keywords: palabra1, palabra2, palabra3,. . ., palabra6.

Índice general

1. Introducción **1**

1.1. Objetivo general 1

1.2. Objetivos específicos 1

1.3. Alcance 1

1.4. Marco teórico 3

2. Metodología **9**

2.1. Base de datos 10

2.1.1. Magnitud de completitud y Ley de Gutenberg-Richter 10

2.2. Dependencia espacio-temporal 11

2.3. Desclusterización de eventos sísmicos 13

2.3.1. Propiedades buscadas tras la desclusterización 13

2.3.2. Algoritmo de Baiesi y Paczuski (2004) 14

2.3.3. Distribución bimodal de $\log_{10}(\eta)$ 15

2.3.4. Estimación del umbral mediante mixtura de normales 16

2.3.5. Función auxiliar de diferencia 17

2.3.6. Análisis de dependencia temporal: Pruebas de Ljung-box y Rachas 19

2.4. Análisis exploratorio del catálogo desclusterizado 19

2.4.1. Densidad espacial 20

2.4.2. Análisis exploratorio del catálogo de sismos desclusterizados 21
2.5. Umbral Crítico y Modelamiento mediante GDP 23

3. Resultados, conclusiones y recomendaciones **26**
3.1. Resultados 26
3.2. Conclusiones y recomendaciones 26

A. Título anexo **27**

Bibliografía **28**

Índice de figuras

2.1. Comparación del conteo de eventos sísmicos antes y después del filtrado por magnitud de completitud. No es que hubiera menos sismos, sino que actualmente se registran con mayor precisión instrumental. 10

2.2. Relación de Gutenberg-Richter: $\log_{10}(N) = a - bM$ para el catálogo de eventos sísmicos filtrado por magnitud de completitud. 11

2.3. Función K de Ripley para el catálogo de eventos sísmicos. Para un patrón de clustering, se cumple que $K(r) > \pi r^2$, lo cual se evidencia estadísticamente también con el valor p=0.01 por Envolventes de Monte Carlo que no cumple con CSR (H_0). 12

2.4. Distribución empírica de la distancia espacio-temporal normalizada en escala logarítmica ($\log_{10}(\eta)$) obtenida mediante el algoritmo de Zaliapin. 16

2.5. Mezcla de dos distribuciones normales ajustadas a cada moda y miden el comportamiento de las poblaciones dependientes (cola izquierda) e independientes (cola derecha) y el umbral de separación entre las poblaciones. 17

2.6. Comportamiento de las densidades en las proximidades de sus medias. Dado que cada componente alcanza su máximo en μ_i. 18

2.7. Función diferencia $f(x) = \lambda_1 f_{\mu_1,\sigma_1}(x) - \lambda_2 f_{\mu_2,\sigma_2}(x)$. Se evidencia el umbral como la raíz de la función f (2.4). 18

2.8. Intensidad de eventos sísmicos principales en la región de estudio. Se observa una mayor concentración de eventos en las zonas cercanas a fallas geológicas activas. 20

2.9. Serie temporal del conteo de eventos que superen el umbral de magnitud propuesto por la ley de Gutenberg-Richter. . . . 21

2.10 Distribución de magnitudes de los eventos sísmicos desclusterizados a escala logaritmica. 22

2.11 Gráfico de elección de umbral (`tcplot`) para el parámetro de escala modificado. 24

2.12 Gráfico de elección de umbral (`tcplot`) para el parámetro de forma ξ. 24

Capítulo 1

Introducción

1.1. Objetivo general

Estudiar las propiedades, características y modelos estadísticos asociados a procesos puntuales marcados.

1.2. Objetivos específicos

1. Analizar las propiedades de primer orden de los procesos puntuales.
2. Promover el desarrollo de modelos con fundamento teórico sólido y orientación aplicada, incentivando la formulación y resolución de problemas reales mediante el uso de datos abiertos.
3. Modelar los valores extremos mediante Procesos Puntuales Marcados.

1.3. Alcance

El alcance de este trabajo se enfocó en la modelación de valores extremos de eventos sísmicos que superen un umbral de magnitud de completitud. Los datos obtenidos de U.S. Geological Survey, [2026], ANSS Comprehensive Earthquake Catalog (ComCat), para el periodo de tiempo

comprendido entre el el 20 de enero de 1904 hasta el 31 de diciembre de 2025 y restrigidos al área de estudio descrita por coordenadas: longitud $-117{,}91°$ a $-34{,}02°$ y latitud $-55{,}77°$ a $32{,}99°$. Ubícandonos así a lo largo de la Cordillera de los Andes, desde el oeste de México hasta el centro sur de Chile, donde la interacción entre la placa de Nazca y la placa Sudamericana concentra la mayor tasa de liberación de energía sísmica del continente. La Ventana de estudio presenta una completitud consistente para magnitudes de $M_w \geq M_c$, vericado mediante la Ley de Gutenberg-Richter.

Los eventos se modelaron como un Proceso Puntual Marcado espacio temporal, donde cada evento se representará por un par (X_i, m_i), donde X_i es la ubicación espacial (localización epicentral) y temporal del evento, y m_i como la magnitud del evento como marca. Previo al modelado, el cátalogo se desclusterizó mediante el algoritmo de Baiesi-Paczuski, [2004], para obtener un conjunto de eventos independientes.

Para el modelamiento de los eventos extremos, se empleó la **Teoría de Valores Extremos** bajo el enfoque de Picos sobre el Umbral (POT), ajustando un conjunto de distribuciones generalizadas de Pareto (GDP) a las excedencias $m_w - \mu$, sobre un umbral $\mu \geq M_c$. La estimación de los parámetros de la distribución se realizó mediante máxima verosimilitud, y su dependencia con covariables físicas, espaciales y temporales, evaluadas mediante modelos aditivos generalizados (GAM) y purebas de verosimilitud.

Para la componentes de ocurrencia se estimará la intensidad del Proceso Puntual Marcado $\lambda(t, x, y)$ del catálogo desclusterizado, vericiado previamente su compatibilidad con un proceso de Poisson no homogéneo. El objetivo final es identificar las zonas y periodos de mayor tasa de ocurrencia de eventos y cuántificar la influencia de las covariables sobre dicha tasa.

Se excluyó del alcance de este trabajo:

- EL modelado de réplicas y secuencias sísmicas.
- La modelación de tsunamis o desplazamientos cosísmicos.
- Eventos con magnitud inferuior a la magnitud de completitud M_c.

1.4. Marco teórico

Los Procesos Puntuales cosntituyen la base teórica para el modelamiento de eventos discretos en el tiempo y espacio, ya que proporcional el lenguaje matemático para lograr describir la ocurrencia de eventos en el espacio y tiempo. Un Proceso Puntual es una medida aleatoria de conteo que registra la cantidad de eventos que se dan en un conjunto dado, y extendiendo la idea a Procesos Puntuales Marcados, es ahora posible asociar a cada evento una caracterísitca de interés, como la magnitud de un sismo, lo que será de utilidad para el modelamiento de valores extremos. Propiedades como la medida de intensidad, medida de covarianza, la convergencia débil de un Proceso Puntual y el concepto de Complete Spatial Randomness (CSR) sirven como una referencia para evaluar el patrón observvados si llega a ser aleatorio o no.

La Teoría de Valores Extremos provee un marco teórico para el modelamiento de valores máximos o excedencias sobre un umbral, mediante las distribuciones límite GEV y GDP, respectivamente.

1. **Procesos Puntuales**

   Definición: Sea $(A, \mathcal{B}(A))$ un espacio medible, donde:

   - A es un conjunto no vacío, y
   - $\mathcal{B}(A)$ es la σ-álgebra de Borel del conjunto A.

   Un Proceso puntual es una medida aleatoria de conteo N definida sobre $(A, \mathcal{B}(A))$.

   $$\begin{aligned} N : \mathcal{B}(A) &\longrightarrow \mathbb{N}_0 \cup \{+\infty\} \\ B &\longmapsto N(B) = \sum_{i=1}^{\infty} \mathbf{1}(x_i \in B) \end{aligned}$$

   Es de interés conocer bajo que condiciones llegamos a considerar que un conjunto de eventos en un dominio dado, se comporta como un Proceso Puntual. Por tanto, se define la **Convergencia débil de un Proceso Puntual** como: Dada sucesión de conteos de eventos $\{N_n\}_{n\in\mathbb{N}}$ en el mismo espacio medible E converge débilmente a

una medida de conteo N de un Proceso Puntual en E si para una colección de subconjuntos acotados $\{A_j\}_{j=1}^{k} \subset E$. Si se cumple que:

$$(N_n(A_1), \ldots, N_n(A_k)) \xrightarrow{d} (N(A_1), \ldots, N(A_k)) \forall n \in \mathbb{N} \qquad \text{y}$$
$$\Pr(N(\partial A_i) = 0) = 1, \quad i = 1, \ldots, k, \ k \geq 1$$

Con ∂A_i la frontera de A_i en el espacio medible E. Se considera que no existen eventos en la frontera del conjunto A_i. [4]

Y un caso en partícular de los Procesos Puntuales son los Procesos de Poisson, que se definen formalmente un Proceso Puntual definido sobre un espacio medible E, tal que:

- Para cualquier conjunto acotado $A \in E$, $N(A)$ sigue una distribución de Poisson con parámetro $\Lambda(A)$.
- Para cualquier colección finita de conjuntos acotados disjuntos $\{A_j\}_{j=1}^{k} \subset E$, las variables aleatorias $N(A_1), \ldots, N(A_k)$ son independientes entre ellas. [3]

Y en el momento que se da una marca a cada evento se define el Proceso Puntual Marcado es un Proceso Puntual N definido sobre $(A, \mathcal{B}(A))$ y un conjunto de marcas M con σ-álgebra $\mathcal{B}(M)$, tal que N es una medida aleatoria de conteo definida sobre $(A \times M, \mathcal{B}(A) \otimes \mathcal{B}(M))$.

$$N : \mathcal{B}(A \times M) \longrightarrow \mathbb{N}_0 \cup \{+\infty\}$$
$$X \times Y \longmapsto N(X \times Y) = \sum_{i=1}^{\infty} \mathbf{1}(x_i \in X, m_i \in Y)$$

Con $N(X \times Y) < \infty$ para todo $X \in \mathcal{B}(A)$ y $Y \in \mathcal{B}(M)$.[3] A continuación se presentan algunas propiedades y definiciones de interés para el modelamiento de procesos puntuales marcados. **Propiedades**

- **Medida de Covarianza de un Proceso Puntual Marcado (γ)** La medida de covarianza del proceso caracteriza las propiedades de segundo orden, cuantificando la dependencia conjunta entre un par de eventos y marcas a lo largo de la ventana de estudio. Sean $A_1, A_2 \in \mathbb{B}(S)$ y $C_1, C_2 \in \mathbb{B}(M)$, la medida de covarianza se

define formalmente como: [3]

$$\gamma(A_1 \times C_1, A_2 \times C_2) = Cov(N(A_1 \times C_1), N(A_2 \times C_2))$$

- **Medida de Intensidad de un Proceso Puntual Marcado.** Sea $\Phi = \{(X_i, M_i)\}_{i=1}^{\infty}$ un Proceso Puntual Marcado en $S \times M$, donde:
  - $X_i \in S$ es la ventana de estudio del conjunto de eventos S,
  - $M_i \in M$ es la marca asociada al evento (X_i) del conjunto de marcas M.

  La medida de intensidad de Φ es el primer momento de la medida aleatoria de conteo N definida sobre $(S \times M, \mathcal{B}(S) \otimes \mathcal{B}(M))$, es decir:

$$\Lambda(A \times C) = \mathbb{E}[N(A \times C)]$$

  Con $A \in \mathcal{B}(S)$ y $C \in \mathcal{B}(M)$. [3]

Complete Spatial Randomness (CSR)

El fenómeno de Complete Spatial Randomness (CSR) hace referencia a un patrón puntual que es completamente aleatorio en el espacio de estudio, es decir, que el proceso es sinónimo de un proceso de Poisson homogéneo, donde la intensidad del proceso es constante en todo el espacio de estudio y los eventos son independientes entre sí.

Este fenómeno se lo mencionará con la siguiente hipótesis nula: H_0 : CSR, y se lo contrastará con la hipótesis alternativa H_1 : No CSR, donde el patrón puntual es no aleatorio y presenta un comportamiento de clusterización, inhibición, intensidad no constante, anisotropía o efectos de borde o errores de medición. [6]

Relación del conteo de eventos bajo ciertas condiciones sigue una distribución de Poisson

2. **Teoría de Valores Extremos**

   La teoría de valores extremos es una rama de la estadística enfocada en analizar eventos en los datos concentrados en las colas de su distribución. Esta teoría prevé un camino para el entendimiento y

modelamiento de los comportamientos de los valores que superen un cierto umbral crítico o en los máximos obtenidos en períodos de interés.

Estableciendo una analogía con el Teorema Central del Límite, la teoría de valores extremos determina un marco teórico para el modelamiento de los datos extremos o máximos de una muestra aleatoria. Existen dos enfoques dentro de la Teoría de Valores Extremos:[1], [2]

- **Máximos por Bloques** Consiste en dividir la serie de datos en bloques contiguos de igual tamaño para extraer el valor máximo de la base de cada uno. La colección de máximos se ajusta a una Distribución de Valores Extremos Generalizada (GEV); sin embargo, si una región de continuos contiene múltiples eventos extremos importantes, solo el mayor es considerado, descartando de esta manera información potencialmente valiosa de los demás datos.
- **Magnitudes mayores a un umbral** Consiste en fijar un umbral crítico u y seleccionar únicamente las observaciones que lo superan. Las magnitudes de estas excedencias se modelan por ejemplo con una Distribución Pareto Generalizada (GPD).

Las funciones de Distribución Generalizada de Valores Extremos y Generalizada de Pareto, respectivamente son: [2]

- Distribución Generalizada de Pareto:

$$H(y;\tilde{\sigma},\xi) = 1 - \left(1 + \frac{\xi y}{\tilde{\sigma}}\right)_{+}^{-1/\xi} \tag{1.1}$$

  Donde:

  - $\tilde{\sigma} > 0$ es el parámetro de escala, y
  - $\xi \in \mathbb{R}$ es el parámetro de forma.

- Distribución Generalizada de Valores Extremos:

$$G(x;\mu,\sigma,\xi) = \exp\left\{-\left[1 + \xi\left(\frac{x-\mu}{\sigma}\right)\right]^{-1/\xi}\right\} \tag{1.2}$$

  Donde:

- $\mu \in \mathbb{R}$ es el parámetro de localización,
- $\sigma > 0$ es el parámetro de escala, y
- $\xi \in \mathbb{R}$ es el parámetro de forma.

Los valores de los parámetros σ y $\tilde{\sigma}$ describen la escala de los datos extremos en los enfoques de máximos por bloques y por umbrales, respectivamente. Por otro lado, la forma de los datos extremos está condicionada por el parámetro ξ en ambos enfoques.

Los parámetros están relacionados debido a que si $\Xi \sim GEV(\mu, \sigma, \xi)$, entonces las excedencias $X - u | X \geq u$ siguen aproximadamento una distribución $GPD(\tilde{\sigma}, \xi)$, con

$$\tilde{\sigma} = \sigma + \xi(u - \mu) \tag{1.3}$$

Por ende, el parámetro de forma ξ es el mismo en ambos enfoques, mientras que el parámetro de escala de la GDP, $\tilde{\sigma}$ dependerá del umbral u.

3. **Modelamiento de Valores Extremos**

   Dentro de la Teoría de Valores Extremos, el método de Picos sobre el Umbral, resulta preferible al de máximos por bloques debido a que se logran aprovechar toda la información disponible de los eventos que lleguen a superar un umbral crítico, este enfoque logra mayor eficiencia en el uso de los datos, pues, las estimaciones de los parámetros de GDP serán más estables cuando el registro es limitado o cuando se modelar excedencias asociadas a un umbral con interpretación física. [2]

   En la realidad, los eventos extremos no ocurren de manera aislada ni tampoco serán estacionarios, por ende los parámetros σ y ξ de la GDP podrán variar en función de covariables físicas y espacio-temporales, por tanto el enfoque POT puede formularse en el marco de los Procesos Puntuales Marcados, donde la ocurrencia de excedencias se describe mediante una función de intensidad λ y el comportamiento de la GDP. Cuando esta dependencia se describe mediante funciones suaves y aditivas se obtiene un Modelo Aditivo Generalizado, el cual ofrece flexibilidad para capturar relaciones no lineales entre covariables y los parámetros fluctuantes.

a) **Modelo Aditivo Generalizado:** Este tipo de modelo se parte de los Modelos Lineales Generalizados (GLM), pero permite que los parámetros de la distribución de probabilidad de la variable respuesta, en este caso la excedencia de la magnitud de los eventos sísmicos, explicados por una función enlace definida como combinación lineal de funciones suaves que dependen de las covariables con el objetivo que se cumplan las restricciones de los parámetros de la distribución y se tenga mayor poder predictivo.

b) **Representación por Bases:** La función enlace de cada parámetro puede representarse mediante:

$$\eta_*(x) = \beta_0 + \sum_{k=1}^{K} \sum_{d=1}^{D_k} \beta_{k,d} b_{k,d}(x)$$

En este caso $\eta_*(x)$ es el predictor aditivo asociado al parámetro $\mu(x)$ que depende de un vector de covariables de dimensión K, y para cada componente del vector de covariables se considera una base de funciones predefinidas y conocidas de dimensión D_k.

c) **Caracterización del Proceso Puntual de Excedencias**

[8]

Capítulo 2

Metodología

Se describe la ocurrencia de eventos sísimicos extremos y el comportamiento en la magnitud en relación a covariables físicas y espaciotemporales. El desarrollo del componente se enmarca en un enfoque cuantitativo, basado en el análisis numérico del registro de sísmos y en la estimación parámetrica de los modelos probabilísticos que mejor llegan a representar los datos. El marco teórico basado en los Procesos Puntuales Marcados (PPM), permite describir conjutamente la ocurrencia espaciotemporal de los eventos y su magnitud como la marca del proceso. Por lo tanto la formulación de la ocurrencia se modela mediante la función condicional $\lambda(t, x, y \mid \mathcal{H}_t)$, mientras que el comportamiento de los eventos se describe con la ayuda de la teoría de valores extremos, el trabajo abordó el enfoque de Picos sobre el Umbral (POT) y la Distribución Generalizada de Pareto (GDP).

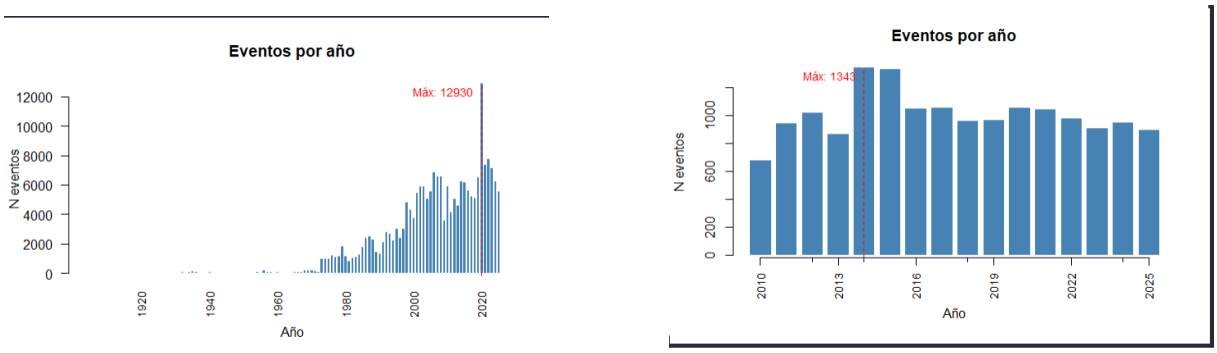
La elección de este marco se sustenta en la literatura científica, que demuestra la eficacia de los PPM para representar procesos sísmicos no estacionarios y la de la GPD para modelar excedencias sobre un umbral físicamente interpretable, destacando su eficiencia en el uso de datos frente a esquemas de máximos por bloques. Además, el enfoque POT puede formularse como un proceso puntual de Poisson no homogéneo mediante la ocurrencia de mangitudes que sobrepasen un umbral crítico.

El método empleado es de tipo hipotético-deductivo. Se parte de la hi-

pótesis central de que la energía sísmica superior a un umbral base puede ser modelada mediante la distribución GPD, cuyos parámetros fluctúan dinámicamente en función de covariables físicas y espaciotemporales. A partir de esta premisa, se deducen implicaciones estadísticas y se ejecutan pruebas empíricas para validar o refutar la hipótesis, evaluando el ajuste de la distribución al someterla a distintos escenarios. En consecuencia, la investigación presenta un diseño explicativo y correlacional, ya que busca evaluar y cuantificar cómo la interacción de las variables físicas y espaciales determinan el comportamiento del parámetro de escala (σ) en el modelo de excedencias.

2.1. Base de datos

Existe un aumento en el número de eventos sísmicos registrados a lo largo del tiempo, como máximo valor tener en el 2014, un registro de 1343 eventos sísmicos. Por ende se trabajó a partir de del primero de enero de 1973.



(a) Catálogo original.

(b) Eventos tras filtrado por M_c y a partir del 2010.

Figura 2.1: Comparación del conteo de eventos sísmicos antes y después del filtrado por magnitud de completitud. No es que hubiera menos sismos, sino que actualmente se registran con mayor precisión instrumental.

2.1.1. Magnitud de completitud y Ley de Gutenberg-Richter

El segundo paso consistió en tener un catálogo fiable y mayormente completo según la Ley de Gutenberg-Richter, la cual describe la relación

entre la magnitud y la frecuencia de los sismos, otorgándonos la ventaja de encontrar una magnitud mínima de completitud a partir del cual se empieza a considerar una relación log-lineal entre la frecuencia y la magnitud. Como resultado de este análisis, se identificó un umbral mínimo de magnitud de $M_c = 1{,}8$, el cual fue utilizado para filtrar los eventos sísmicos y sea consistente la Ley de Gutenberg-Richter. Dado que el análisis de valores extremos requiere una cola superior bien definida y que la desclusterización por vecino más cercano pierde validez con magnitudes muy bajas, se adoptó por definir un umbral $M_c = 4{,}5$.

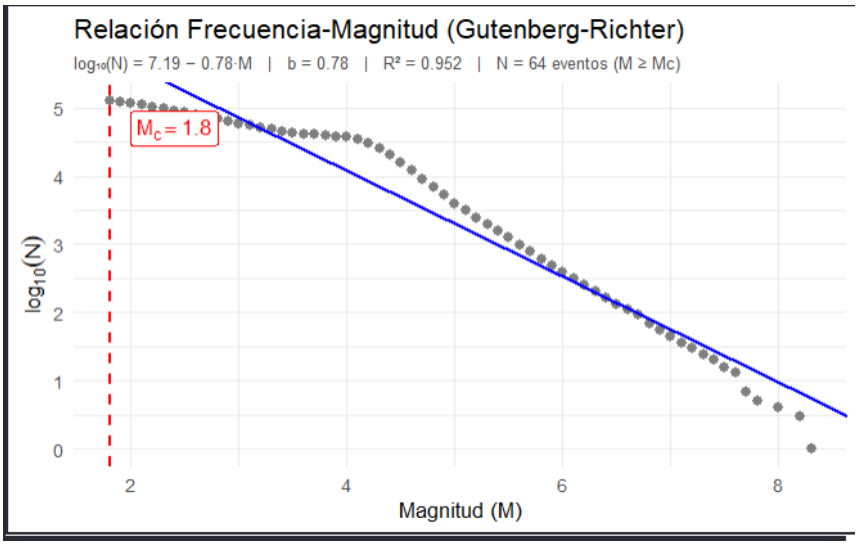


Figura 2.2: Relación de Gutenberg-Richter: $\log_{10}(N) = a - bM$ para el catálogo de eventos sísmicos filtrado por magnitud de completitud.

2.2. Dependencia espacio-temporal

Ahora, con un catálogo completo y ordenado, se debe hacer un diagnóstico acerca de sus dependencias espacio-temporales, se busca evaluar si dentro de la componente espacial existe la posibilidad de ver CSR, clustering e inhibición. Se espera que se evidencie un patrón de clustering, pues al estar cerca de fallas geológicas los inicios del sismo se concentran en ciertas zonas geográficas, generando un agrupamiento de eventos. Una manera sencilla de evaluar esta dependencia espacial es mediante la función K de Ripley, la cual permitirá determinar si existe un patrón en específico.

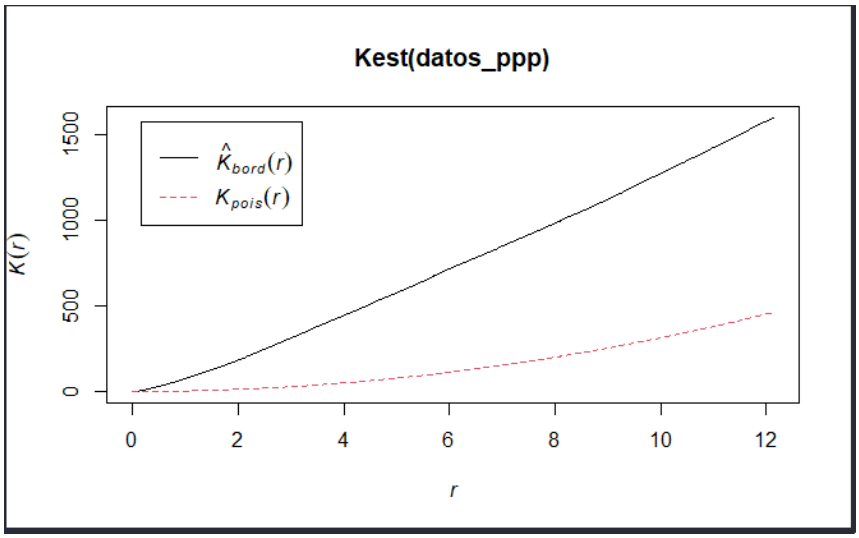


Figura 2.3: Función K de Ripley para el catálogo de eventos sísmicos. Para un patrón de clustering, se cumple que $K(r) > \pi r^2$, lo cual se evidencia estadísticamente también con el valor p=0.01 por Envolventes de Monte Carlo que no cumple con CSR (H_0).

Por lo tanto, en la componente espacial hay certeza de una clusterización de eventos, era lo esperado. Ahora, en cuanto a la dependencia temporal, se busca evaluar si existe un patrón de CSR principalmente; o, secundariamente inhibición o clustering de eventos en el tiempo. Se espera en sismicidad natural, lo habitual. Antes de limpiar el catálogo de datos, es conocido que surge un agrupamiento de eventos sísmicos provocados por las secuencias de réplicas y no por un patrón de CSR, en cuyo caso será necesario aplicar su desclusterización filtrando los eventos que provoquen réplicas en función del intervalo de tiempo entre estos.

Previo a la desclusterización, el análisis de la dependencia temporal consideró los valores "p"de las pruebas de Ljung-Box y de Rachas. La primera analiza la autocorrelación en los retardos temporales; mientras que la segunda (test de Rachas) detecta desviaciones de la aleatoriedad de eventos sísmicos en el tiempo mediante la binarización de los intervalos entre eventos, clasificándolos en función de si superan o no la mediana muestral; y, la cantidad de rachas para comparar con lo esperado bajo aleatoriedad. Entonces, si se encuentran pocas rachas que cumplan el factor, significa que hubo mayor cantidad de agrupamientos de eventos sísmicos, es decir de réplicas; en otras palabras, es evidente que la ac-

tividad sísmica está sujeta a una dependencia temporal. De existir una importante cantidad de rachas, es evidente que se estaría frente a un patrón con mayor alternancia de estados provocado posiblemente por inhibición o regularidad de eventos.

Prueba de Ljung-Box	
Estadístico	122.8731
p-valor	0.0002
Existe dependencia temporal	

Prueba de Rachas	
Estadístico	$-11{,}9653$
p-valor	0.007
Existe dependencia temporal	

Cuadro 2.1: Diagnóstico de dependencia temporal antes de la desclusterización entre eventos sísmicos.

2.3. Desclusterización de eventos sísmicos

2.3.1. Propiedades buscadas tras la desclusterización

A continuación se realizará la desclusterización de los eventos sísmicos como buena práctica para dar más seguridad al postulado de independencia de estos eventos: $N_{t_1}, N_{t_2} - N_{t_1}, \ldots, N_{t_n} - N_{t_{n-1}}$.

Una vez aplicado el algoritmo de desclusterización se garantiza que:

- Si $s \leq t$ entonces $N_s \leq N_t$
- Para todo $n > 0$ y la sucesión creciente de tiempos $\{t_i\}_{i=1}^{n}$ se cumple que $N_{t_1}, N_{t_2} - N_{t_1}, \ldots, N_{t_n} - N_{t_{n-1}}$ son independientes.

En el primer punto, los sismos se cuentan de manera acumulativa en el tiempo, y para el segundo punto, la desclusterización elimina las réplicas y secuencias dependientes asociadas a los eventos principales en un bloque de tiempo; la ocurrencia de sismos en el intervalo no condiciona ni aporta información sobre su conteo en el siguiente bloque disjunto, garantizando que los incrementos estocásticos en intervalos de tiempo consecutivos sean independientes.

2.3.2. Algoritmo de Baiesi y Paczuski (2004)

El algoritmo de desclusterización utilizado es el propuesto por Baiesi y Paczuski, 2004, el cual se basa en reconocer en una red de fallas geológicas los sismos más cercanos a un evento principal, para seguidamente poder filtrarlos en función de la magnitud del evento principal y de la distancia espacial y temporal de los eventos asociados. La idea es que un evento principal pueda generar un conjunto de eventos dependientes en una ventana de tiempo y espacio, los cuales deberán ser eliminados del catálogo de eventos sísmicos para garantizar la independencia de los incrementos estocásticos.

Entonces se deberá calcular los vecinos más cercanos en función de la magnitud de cada evento principal. Para ello la idea es calcular una distancia de interacción entre eventos sísmicos, definida por:

$$\eta_{ij} = \begin{cases} (r_{ij})^{d_f} 10^{-b(m_i)}(t_j - t_i), & \text{si } t_j > t_i, \\ \infty, & \text{si } t_j \leq t_i, \end{cases} \tag{2.1}$$

Notemos varios puntos de la ecuación anterior:

- r_{ij} es la distancia espacial entre los epicentros de los eventos i y j.
- d_f es la dimensión fractal del epicentro en la red de fallas geológicas, la cual se estima en $d_f = 1{,}6$ para la región de estudio. Mide en promedio qué tanto decae la densidad de las réplicas luego del evento.
- b es el parámetro de la Ley de Gutenberg-Richter, el $b \sim 1$ para la región de estudio. Mide la relación entre la magnitud y la frecuencia de los eventos sísmicos.
- m_i es la magnitud del evento principal i que debe superar por lo anterior dicho a m_c.
- $t_j - t_i$ es el intervalo de tiempo entre los eventos i y j, el cual debe ser positivo para que el evento j pueda ser considerado como una réplica del evento i.

- $10^{-b(m_i)}$ ayudará a establecer que a grandes magnitudes la distancia η_{ij} deberá ser más cercana.

Y para cada evento j se buscará su padre i que minimice la distancia de interacción η_{ij}, es decir, el evento principal más cercano en el tiempo y espacio. Como siguiente paso, se deberá calcular las interacciones temporales y espaciales, normalizadas por un factor en función de la magnitud del evento principal:

$$T_{ij} = 10^{-qb(m_i)}(t_j - t_i), \quad R_{ij} = 10^{-pb(m_i)} r_{ij}^{d_f}, \tag{2.2}$$

con $p + q = 1$, y $p, q \in [0, 1]$. En este caso se tomará $p = 0{,}5$ y $q = 0{,}5$, para dar el mismo peso a la interacción temporal y espacial.

Con las ecuaciones de interacción temporal y espacial, se puede definir una interacción η_j, el cual se define en función de $\log_{10}(T_j)$ y $\log_{10}(R_j)$, y se puede calcular como:

$$\log_{10}(\eta_j) = \log_{10}(T_j) + \log_{10}(R_j) \tag{2.3}$$

Notemos que el valor de η_j mide la distancia entre los eventos j y sus padres, y medirá la dependencia temporal y espacial entre estos. Si $T_j \to 0$ y/o $R_j \to 0$, entonces $\eta_j \to 0$, lo cual significa que el evento j es una réplica del sismo padre. Por otro lado, si $\eta_j \to \infty$, entonces el evento j es independiente del evento principal porque estará más alejado en el tiempo o espacio.

2.3.3. Distribución bimodal de $\log_{10}(\eta)$

Además, esta interacción con datos sísmicos generará una distribución bimodal, pues presentará dos modas por la mezcla de dos comportamientos, en este caso; una rama se caracterizará por los eventos que estén alejados (lejanía temporal o espacial), en cambio la otra rama tendrá los sismos más cercanos al evento principal, clasificándolos como dependientes.

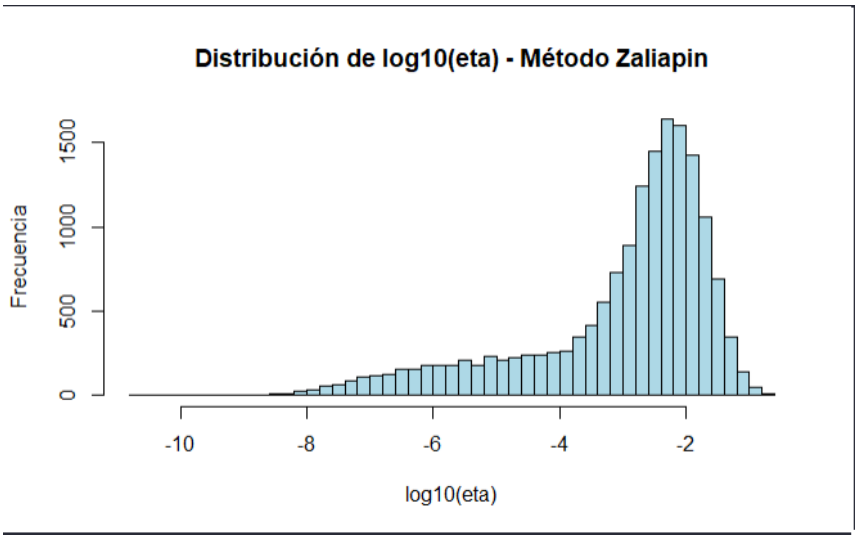


Figura 2.4: Distribución empírica de la distancia espacio-temporal normalizada en escala logarítmica ($\log_{10}(\eta)$) obtenida mediante el algoritmo de Zaliapin.

Como se mencionó y se observa en el gráfico anterior, el histograma de los valores $\log_{10}(\eta)$ presenta dos comportamientos con modas diferentes. La rama izquierda, con valores mucho más negativos, concentra los eventos dependientes; en ella, la proximidad espacial y temporal respecto a un evento principal es alta ($\eta_j = T_j \cdot R_j \approx 0$). Por otro lado, la rama derecha, con una concentración alrededor de -2, agrupa los eventos independientes, ya que los valores de η_j se alejan de 0 al no mostrar cercanía espacial ni temporal respecto al evento principal.

2.3.4. Estimación del umbral mediante mixtura de normales

Para separar ambas ramas, existen varios criterios: (i) tomar el mínimo local de la densidad empírica en la zona de transición entre ambas modas como umbral; o (ii) ajustar una mezcla de dos distribuciones normales a los valores de $\log_{10}(\eta)$ y tomar como umbral el punto de intersección entre ambas densidades ajustadas.

En este trabajo se optó por el criterio analítico de estimar una mixtura de distribuciones normales. Para lograrlo se empleó el algoritmo Expectación–Maximización (EM) para mixtura de normales (Benaglia, T.,

Chauveau, D., Hunter, D. R., & Young, D. S. (2009)) implementado en el paquete **mixtools** de R. Una vez aplicado y obtenidos los parámetros necesarios: vector de pesos λ, vector de medias μ, vector de desviaciones estándar σ. El umbral η_0 se define como el valor de $\log_{10}(\eta_j)$ donde las dos densidades ajustadas se intersecan, lo que corresponde al punto de separación entre los eventos dependientes e independientes.

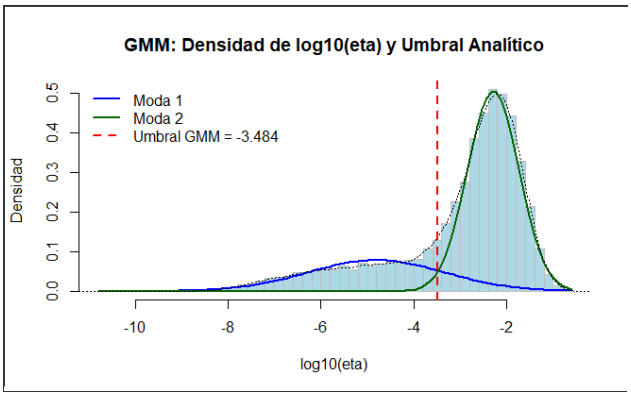


Figura 2.5: Mezcla de dos distribuciones normales ajustadas a cada moda y miden el comportamiento de las poblaciones dependientes (cola izquierda) e independientes (cola derecha) y el umbral de separación entre las poblaciones.

2.3.5. Función auxiliar de diferencia

El umbral se obtuvo de resolver $f(x) = 0$ con f una función auxiliar, definida como:

$$f(x) = \lambda_1 f_{\mu_1,\sigma_1}(x) - \lambda_2 f_{\mu_2,\sigma_2}(x), \qquad x \in [\text{mín}(\mu_1,\mu_2),\ \text{máx}(\mu_1,\mu_2)], \qquad \lambda_1,\lambda_2 > 0. \tag{2.4}$$

Donde f_{μ_i,σ_i} es la densidad normal de cada población i. Con el resultado de que nuestro umbral es $\eta_0 \approx -3{,}484$.

Se tratará cada moda de cada población como la moda de cada distribución normal, que justamente coincide con su media, y ahora supongamos que sin pérdida de generalidad, que $\mu_1 < \mu_2$. Entonces en el intervalo $[\mu_1, \mu_2]$ la densidad f_{μ_1,σ_1} es decreciente pues a la derecha de su media la densidad normal decrece y f_{μ_2,σ_2} es creciente pues a la izquierda de su media la densidad normal crece. Por lo tanto, la función f es

continua y decreciente en $[\mu_1, \mu_2]$ debido a que la suma de una función decreciente y del negativo de una función creciente, ambas decrecientes, es decreciente. Se cumple también que $f(\mu_1) > 0$ y $f(\mu_2) < 0$, debido a que se tiene que $f_{\mu_1,\sigma_1}(\mu_1) > f_{\mu_2,\sigma_2}(\mu_1)$ y $f_{\mu_2,\sigma_2}(\mu_2) > f_{\mu_1,\sigma_1}(\mu_2)$, dado que el valor máximo de una normal h se encuentra en su media, es decir, $h_{\mu,\sigma}(\mu) > h_{\mu,\sigma}(x)\ \forall x \in \text{dom}(h_{\mu,\sigma})$.

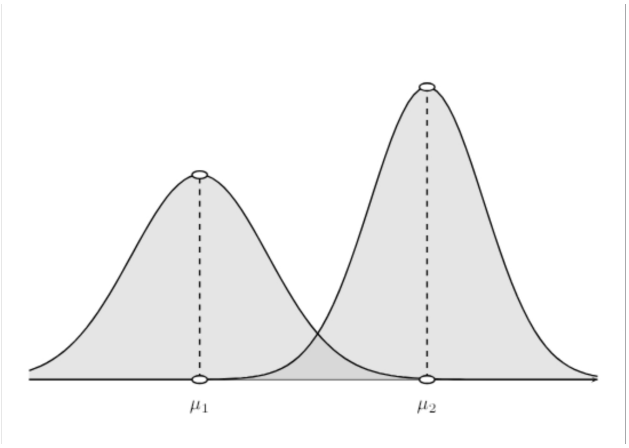


Figura 2.6: Comportamiento de las densidades en las proximidades de sus medias. Dado que cada componente alcanza su máximo en μ_i.

Entonces por el Teorema del Valor Intermedio (Bolzano, 1817), se tiene que la función f de la ecuación 2.4 posee una raíz; en este caso es el umbral que separará los datos dependientes e independientes.

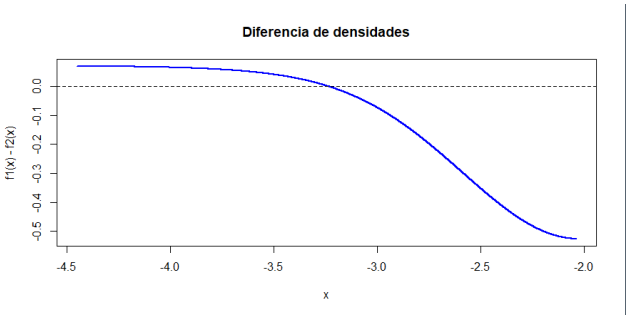


Figura 2.7: Función diferencia $f(x) = \lambda_1\, f_{\mu_1,\sigma_1}(x) - \lambda_2\, f_{\mu_2,\sigma_2}(x)$. Se evidencia el umbral como la raíz de la función f (2.4).

2.3.6. Análisis de dependencia temporal: Pruebas de Ljung-box y Rachas

Ahora con el nuevo catálogo de eventos sísmicos desclusterizados, se vuelve a realizar el análisis de dependencia temporal mediante las pruebas de Ljung-Box y Rachas. Se espera que los resultados de estas pruebas indiquen independencia temporal, lo cual confirmaría la efectividad del proceso de desclusterización.

Prueba de Ljung-Box	
Estadístico	0.0607
p-valor	0.8054
Existe independencia temporal	

Prueba de Rachas	
Estadístico	0.9769
p-valor	0.3286
Existe independencia temporal	

Cuadro 2.2: Diagnóstico de dependencia temporal **después** de la desclusterización. Ambas pruebas confirman la independencia temporal de los eventos sísmicos principales.

2.4. Análisis exploratorio del catálogo desclusterizado

Una vez que se ha obtenido un catálogo de eventos sísmicos independientes en la componente temporal y a la vez también la independencia de las diferencias estocásticas, se procedió a realizar un análisis exploratorio de los datos. Este análisis tiene como objetivo identificar patrones, tendencias y características relevantes de los eventos sísmicos principales, así como evaluar la distribución de magnitudes y la densidad espacial de los sismos.

2.4.1. Densidad espacial

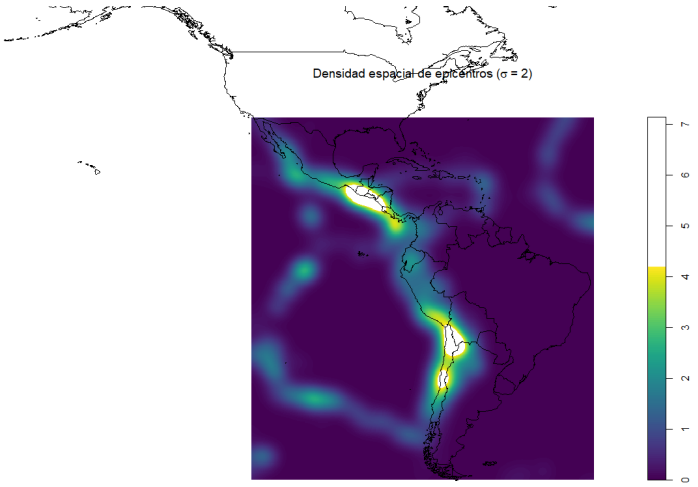


Figura 2.8: Intensidad de eventos sísmicos principales en la región de estudio. Se observa una mayor concentración de eventos en las zonas cercanas a fallas geológicas activas.

La distribución espacial de los epicentros evidencia un patrón heterogéneo con las zonas de mayor densidad concentradas en el Cinturón de Fuego del Pacífico, desde el oeste de México, pasando por centroamérica y la cordillera de los Andes, pasando a lo largo de Colombia, Ecuador, Perú y Chile. Estas concentraciones coinciden con los bordes de placa activos, donde la actividad sísmica es más intensa debido a la interacción de las placas tectónicas. lo cual es consistente con la tectónica regional y respalda la hipótesis de que la sismicidad no es homogénea en el espacio.

Este comportamiento espacialmente no homogéneo, más adelante, justificará la incorporación de covariables geográficas y geológicas en el modelado del parámetro de escala de la GPD, ya que la intensidad sísmica no puede considerarse constante sobre el dominio de estudio.

2.4.2. Análisis exploratorio del catálogo de sismos desclusterizados

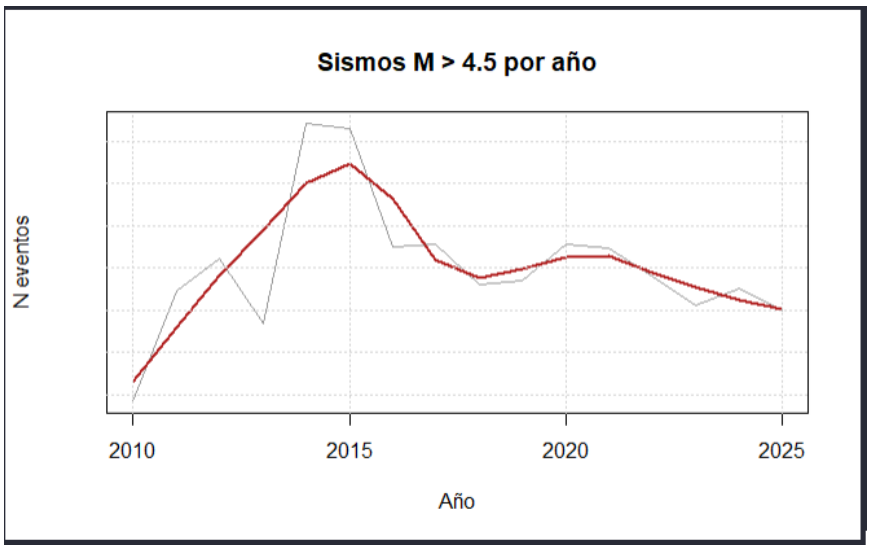


Figura 2.9: Serie temporal del conteo de eventos que superen el umbral de magnitud propuesto por la ley de Gutenberg-Richter.

En la figura 2.9 se muestra una variabilidad considerable a lo largo del tiempo, debido a que la desclusterización en la componente temporal elimina los eventos dependientes, lo que genera una serie temporal más estable (cercana al valor medio del Número de Sismos) y menos afectada por agrupamientos de eventos. Algo que se logró comprobar con las pruebas de independencia temporal. Este gráfico confirma de manera visual que la desclusterización temporal ha sido efectiva.

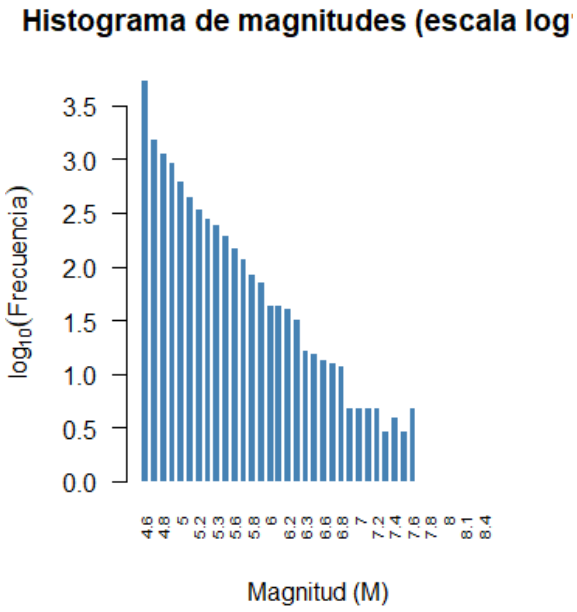


Figura 2.10: Distribución de magnitudes de los eventos sísmicos desclusterizados a escala logaritmica.

Por el otro lado, el histograma 2.10 revela el decaimiento exponencial esperado con la magnitud entre $4{,}6 \leq M \leq 7{,}4$, de acuerdo a la ley de Gutenberg=Ritcher. El ajuste en esta zona produce $b = 0{,}972$ con $R^2 = 0{,}9975$. Por encima de $M \approx 7{,}4$, la frecuencia de eventos con esa marca llega a tener valores de 1 a 2. Además el catálogo contiene eventos hasta $M = 8{,}3$, lo que proporciona $N = 8982$ excedencias sobre $\mu = 4{,}5$, suficiente para el análisis POT. Para cada umbral inicial se presenta la cantidad de eventos disponibles que lo superan.

Umbral μ	$N(M > \mu)$
4.50	8982
4.75	4967
5.00	2248
5.25	1433
5.50	709
5.75	433
6.00	230
6.25	144
6.50	78

Cuadro 2.3: Número de excedencias $N(M > u)$ para distintos umbrales u en el catálogo desclusterizado.

2.5. Umbral Crítico y Modelamiento mediante GDP

Fundamentandose en la convergencia débil de variables, aleatorias, presentamos la variable $m_i - u$ con m_i como la magnitud del evento sísimico i y u un real positivo tal que supera el valor propuesto de la magnitud mínima de G-R. Debemos notar que su función de probabilidad condicionada a las magnitudes que superan u.

$$F_u(y) = Pr(M - u \leq y | M - u \geq 0) = \frac{F(u+y) - F(u)}{1 - F(u)}, y \geq 0, [7] \tag{2.5}$$

converge débilmente a una GDP cuando u se apróxima al extremo superior del soporte de F_u. Formalmente;

$$\lim_{u \to x_F} \sup_{y>0} |F_u(y) - GDP(y; \sigma(u), \xi)| = 0. \tag{2.6}$$

$$x_F = sup\{x \in \mathbb{R} : F(x) < 1\} \tag{2.7}$$

Con la distribución GDP mencionada en **??**.

Es necesario encontrar el umbral crítico u que establecerá la convergencia hacia una GDP. La elección del umbral u muchas veces se es

escogido según el objetivo de la actividad, por ejemplo medir que tanto resistirá la barrera que separa al mar. [5]

Pero en este caso la selección de u se la hizo mediante un enfoque visual a la gráficas de *tcplot*, buscando la estabilidad de cada parámetro de la GDP, es decir, que el valor del parámetro no cambie en función de la elección del umbral. Se busca que se cumpla para cada parámetro:

- X_i sea invariante al umbral.

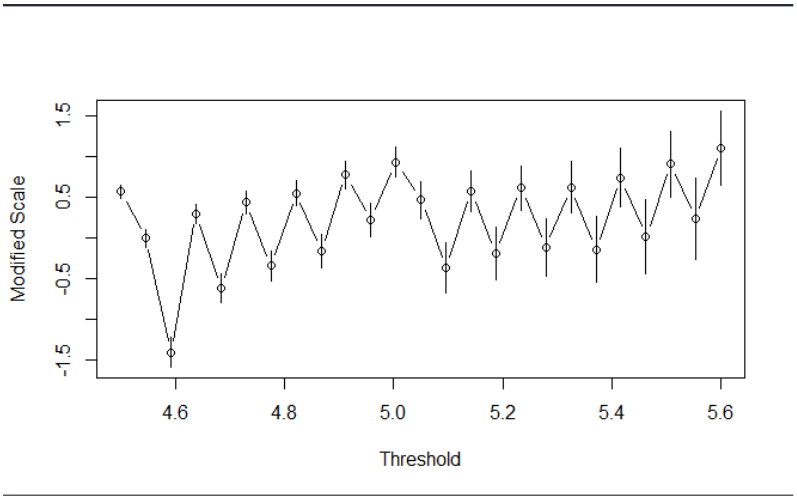


Figura 2.11: Gráfico de elección de umbral (`tcplot`) para el parámetro de escala modificado.

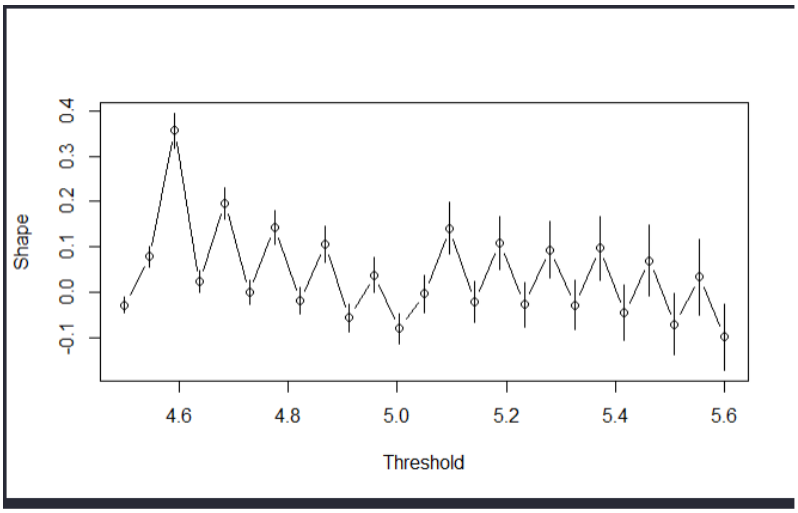


Figura 2.12: Gráfico de elección de umbral (`tcplot`) para el parámetro de forma ξ.

Se busca encontrar un umbral crítico u tal que estabalice el valor de cada parámetro de la distribución GDP. Bajo la hipotesis que la excedencias $X_i - u$ siguen la distribución GDP, por ende, los parámetros deben permanecer aproximadamente constantes. El valor escogido es el menor valor a partir el cual los parámetros estimados de σ y ξ se mantienen estables. Se tomó el umbral $u = 5{,}2$.

Como primer acercamiento, es estimó la distribución GDP con el umbral definido y con los parámetros de escala y forma constantes, obteniendo el siguiente comportamiento:

Parámetro	Estimación	Error estándar	t	p-valor
$\log(\sigma)$ (intercepto)	$-0{,}64$	$0{,}03$	$-19{,}00$	$< 2 \times 10^{-16}$
ξ (intercepto)	$-0{,}08$	$0{,}02$	$-3{,}82$	$6{,}6 \times 10^{-5}$

Cuadro 2.4: Estimaciones del modelo GPD estacionario para las excedencias sobre $u = 5{,}2$.

Como se mencionó anteriormente el enfoque POT es el más eficiente y fue considerado para el modelamiento de eventos extremos. Por tanto, un paso clave es definir en nuestra base de datos un candidato al umbral crítico que separará los eventos extremos del catálogo de sísmos. En la práctica dependerá mucho el objetivo del estudio para definir el valor del umbral crítico, pero en este caso, el umbral crítico fue obtenido mediante el método visual *tcplot* el cual verifica la estabilidad de los parámetros σ y ξ de la GPD para umbrales crecientes.

Capítulo 3

Resultados, conclusiones y recomendaciones

3.1. Resultados

Exponer los resultados obtenidos.

$$x^2 + y^2 = z^2 \tag{3.1}$$

3.2. Conclusiones y recomendaciones

Presenta lo novedoso del trabajo de integración curricular, así como el cumplimiento o no de lo propuesto en los objetivos. En el caso en que no se cumpla uno o varios objetivos, y no se logren los resultados esperados, se propone una posible respuesta que explique por qué sucedió esto o las falencias de la planteado.

Indicar las recomendaciones formuladas a partir del desarrollo de este trabajo de integración curricular.

Capítulo A

Título anexo

En caso necesario, el documento escrito deberá incluir los anexos y secciones que incorporan información que sea relevante, pero que, por su extensión, no pueden ser incorporadas directamente en ninguna de las secciones anteriores.

Referencias bibliográficas

[1] Certificate in Quantitative Finance (CQF). What is Extreme Value Theory? https://www.cqf.com/blog/quant-finance-101/what-is-extreme-value-theory, 2024. Accedido en julio de 2026. Análisis introductorio sobre el enfoque Block Maxima y Peaks Over Threshold (POT).

[2] Stuart Coles. *An Introduction to Statistical Modeling of Extreme Values*. Springer Science & Business Media, London, 2001. El Capítulo 3 sustenta la GEVD y el Teorema de Fisher-Tippett-Gnedenko. El Capítulo 4 detalla el método POT y la GPD.

[3] Daryl J. Daley and David Vere-Jones. *An Introduction to the Theory of Point Processes: Volume I: Elementary Theory and Methods*. Springer Science & Business Media, 2003.

[4] Daryl J. Daley and David Vere-Jones. *An Introduction to the Theory of Point Processes: Volume II: General Theory and Structure*. Springer Science & Business Media, New York, 2nd edition, 2008.

[5] Lord Waverley. Report of the departmental committee on coastal flooding. Technical Report Cmd. 9165, Her Majesty's Stationery Office, London, 1954.

[6] Paula Moraga. *Spatial Statistics for Data Science: Theory and Applications with R*. CRC Press, Boca Raton, 2023. El Capítulo sobre Complete Spatial Randomness detalla las pruebas de hipótesis y funciones diagnósticas para el modelamiento de patrones puntuales.

[7] James Pickands. Statistical inference using extreme order statistics. *The Annals of Statistics*, 3(1):119–131, 1975.

[8] Benjamin D. Youngman. evgam: An R package for generalized additive extreme value models. *Journal of Statistical Software*, 103(3):1–26, July 2022.