

Análisis de Valores Extremos en Datos Sísmicos

Daniel Lara

Table of contents


0.1	La Ley de Gutenberg-Richter (G-R)	1
0.2	Análisis de Extremos: Máximos por Bloques (GEV)	3
0.3	Análisis de Picos sobre el Umbral (POT)	4
0.4	Diagnóstico de Independencia y Declustering	5
0.4.1	Prueba de Independencia	5
0.4.2	Declustering	5
0.4.3	Diagnóstico del PP	6
0.5	Ajuste de Modelos de Excedencia (Procesos Puntuales / GPD)	6
0.5.1	Ajuste del Modelo GEV	6
0.5.2	Parámetros iniciales aleatorios	7
0.5.3	Con parámetros iniciales obtenidos del ajuste GEV previo:	8
0.5.4	Sin parámetros iniciales (modelo estándar GPD)	9
0.6	Las r observaciones más grandes	10
0.7	Ajuste de parámetros con covariables	11
0.7.1	Preparación de datos	12
0.7.2	Modelo 0: Scale constante	12
0.7.3	Modelo 1: Scale en función (lineal) del tiempo	13
0.7.4	Modelo 2: Scale en función del tiempo con splines cúbicos	14
0.7.5	Modelo 3: Scale en función de Longitud y Latitud	15
0.7.6	Modelo 4: Scale en función a la profundidad y distancia a fallas	17
0.7.7	Modelo 5: Scale en función del tiempo y magnitudes espaciales	18
0.8	Selección y Comparación de Modelos	19
0.8.1	Criterios de Información y Verosimilitud Penalizada, para M0,M1,M2, M3,M4, M5	19
0.8.2	Gráfico de Residuos Cruzados	20

0.1 La Ley de Gutenberg-Richter (G-R)

$$\log_{10}N(M) = a - bM$$


- $N(M)$ es el número acumulado de sismos con una magnitud mayor o igual a M .
- a es una constante que indica la tasa de sismicidad total de la región (un valor más alto significa mayor actividad sísmica general).
- b (conocido como el b -value) es una constante que describe la proporción entre sismos pequeños y grandes.

La de Gutenberg-Richter dicta que los datos deberían formar una línea recta perfecta.



A partir del valor mínimo de M_c (magnitud de completitud), la ley de G-R se aproxima a cumplirse, por ende, se debe trabajar con los datos por encima de este valor. Logrando que se garantice el supuesto de Poisson y será más práctica la implementación de los modelos.

0.2 Análisis de Extremos: Máximos por Bloques (GEV)





- **Gráfico de Probabilidades (P-Plot):** Podemos notar que las probabilidades reales se llegan a adaptar bien a las teóricas predichas por el modelo GEV.
- **Gráfico de Cuantiles (Q-Plot):** Las magnitudes van de 6 a 9, notamos que ajusta bien los valores más probables, sin embargo, en los extremos predichos ya se alejan de los datos reales y aumenta la incertidumbre.
- **Nivel de Retorno:** Nos muestra que los sismos entre 6 a 7.5 ocurren en periodos de 0.5 a 5 años; sin embargo, los sismos de magnitud 8, por ejemplo, ocurren cada 50 años.

Máxima de estabilidad por los hablado anteriormente, los datos se llegan a ajustar bien a un modelo GEV, por lo tanto, decimos que es la única distribución de los datos que es máxima estable Extremal Types Theorem y dado que el valor de $\xi_i > 0$, estamos en una GEV.....

0.3 Análisis de Picos sobre el Umbral (POT)

Gráfico de Vida Media Remanente para Sismos





Se toma un umbral entre 5 a 6, se tomará el valor de $\mu = 5$

Se evidencia posiblemente que el parámetro $\xi > 0$ mostrando que las colas serán ligeras con un límite máximo

0.4 Diagnóstico de Independencia y Declustering

0.4.1 Prueba de Independencia

=== PRUEBA DE RACHAS PARA INDEPENDENCIA ===

Estadístico: -36.9075

p-valor: 0

0.4.2 Declustering


=== PRUEBA DE LJUNG-BOX (INDEPENDENCIA TEMPORAL) ===

Estadístico: 799.335

p-valor: 0

0.4.3 Diagnóstico del PP

post-Declustering




por qué se abren los IC? si ya eliminamos las replicas

0.5 Ajuste de Modelos de Excedencia (Procesos Puntuales / GPD)

0.5.1 Ajuste del Modelo GEV

loc	scale	shape
7.2658467	0.4306266	-0.1092916




0.5.2 Parámetros iniciales aleatorios

```

loc      scale      shape
8.2233691 0.2117894 -0.1541443

loc      scale      shape
0.057039567 0.011257730 0.007944734

```



El npp es correcto porque son una recopilación horaria por cada día del año


0.5.3 Con parámetros iniciales obtenidos del ajuste GEV previo:

```

      loc      scale      shape
8.2212478  0.2113051 -0.1544939

      loc      scale      shape
0.056868482  0.011218306  0.007937616


```



0.5.4 Sin parámetros iniciales (modelo estándar GPD)

```
scale      shape
0.5726232 -0.1122663
```

```
scale      shape
0.01347679 0.01454875
```



0.6 Las r observaciones más grandes

Número de excedencias totales: 13670

Número de años: 122

Número de bloques (años): 56

Número de observaciones por bloque: 112

=== TABLA COMPARATIVA MODELOS r -largest ===

	Modelo	r	NLLH	AIC	Convergencia
r-largest	(r = 7)	7	-313.13	-620.26	0
r-largest	(r = 6)	6	-224.79	-443.57	0
r-largest	(r = 5)	5	-159.53	-313.06	0
r-largest	(r = 4)	4	-71.45	-136.91	0
r-largest	(r = 3)	3	-12.99	-19.97	0
r-largest	(r = 2)	2	17.54	41.07	0

Mejor modelo: r = 7 con AIC = -620.26

=== PARÁMETROS ESTIMADOS DEL MEJOR MODELO ===

[1] 7.3251 0.3856 -0.1798

Errores estándar:

[1] 0.0415 0.0220 0.0426

0.7 Ajuste de parámetros con covariables

EVGAM busca estimar los parámetros μ, σ, ξ por medio de combinaciones lineales con funciones llamadas B-splines que dependen de covariables (tiempo, magnitud, etc)

$$\mu(t) = \sum_{j=1}^k \beta_j b_j(t)$$

- $b_j(t)$ son las funciones base para estimar la función suave que describe la tendencia
- B_j parámetros libres que ajustan la Máxima Verosimilitud Penalizada (la forma como ajusta los parámetros)

Y trata de acercar los parámetros maximizando la log-verosimilitud penalizada

$$L_p(\beta) = l(\beta) - \frac{1}{2} \sum_j \lambda_j \beta^\top S_j \beta$$

- $l(\beta)$: Es la log-verosimilitud convencional (la bondad de ajuste).

- λ_j : Es el **parámetro de suavizado** (smoothing parameter). Es la perilla que controla qué tanto castigamos la falta de suavidad. (grande muy suave, pequeño curva muy flexible, tal vez sobreajustada)
- $\hat{S}_j$: Es una medida de la “curvatura” o rugosidad de la función. Si la línea sube y baja bruscamente, este término es muy grande.

Dentro de la formula para el uso del modelo EVGAM tenemos tres tipo de interacciones de las covariables

- $s(x) + s(y)$ Los efectos de x,y son independientes
- $te(x, y)$ existe interacción completa entre x,y
- $ti(x, y)$ cuantifica la interacción pura (se la complementa por ejemplo con $s(x) + s(y)$)

0.7.1 Preparación de datos

Se toma la diferencia con el mínimo para tener un tiempo inicial dentro de los datos que exceden el umbral

0.7.2 Modelo 0: Scale constante

=== MODELO 0: GPD ESTACIONARIO ===

**** Parametric terms ****

logscale


	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.34	0.01	-25.08	<2e-16

shape

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.15	0.01	-18.95	<2e-16

**** Smooth terms ****


GPD QQ Plot



por qué se abren los intervalos?

0.7.3 Modelo 1: Scale en función (lineal) del tiempo

GPD QQ Plot



=== MODELO 2: Tendencia temporal en la escala ===

** Parametric terms **


```
logscale
      Estimate Std. Error t value Pr(>|t|)
(Intercept)    0.33      0.03  10.79  <2e-16
time_years    -0.01      0.00 -23.95  <2e-16
```

```
shape
      Estimate Std. Error t value Pr(>|t|)
(Intercept)   -0.14      0.01 -21.29  <2e-16
```

**** Smooth terms ****

0.7.4 Modelo 2: Scale en función del tiempo con splines cúbicos

GPD QQ Plot



=== MODELO 2: Tendencia temporal en la escala ===

**** Parametric terms ****

```
logscale
      Estimate Std. Error t value Pr(>|t|)
(Intercept)   -0.42      0.01 -32.12  <2e-16
```

```
shape
      Estimate Std. Error t value Pr(>|t|)
```

```
(Intercept)      -0.15          0.01    -20.89    <2e-16
```


```
** Smooth terms **
```

```
logscale
```

```
              edf max.df Chi.sq Pr(>|t|)
s(time_days)  8.13      9  751.99    <2e-16
```

Lo que se puede rescatar aquí es el $s(\text{year_decimal})$ donde la escala σ_t fue cambiando a lo largo del tiempo de formas drásticas, se evidencia por los grados de libertad efectivos cercanos a 8 (miden la complejidad real de una curva suave ajustada).

El valor promedio de σ_t es cercano a 0, lo que podría indicar que las excedencias son más predecibles



Son los valores que aumentarán la varianza promedio a lo largo del tiempo, se los puede predecir y ver como irá cambiando la varianza\

$$\log(\sigma_t) = -0.42 + s(\text{year_decimal})$$

0.7.5 Modelo 3: Scale en función de Longitud y Latitud

```
** Parametric terms **
```

```
logscale
```

```
Estimate Std. Error t value Pr(>|t|)
```

(Intercept)	-0.34	0.01	-24.74	<2e-16
-------------	-------	------	--------	--------

shape


	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.17	0.01	-20.98	<2e-16

** Smooth terms **

logscale


	edf	max.df	Chi.sq	Pr(> t)
s(longitude,latitude)	21.47	29	158.92	<2e-16

GPD QQ Plot



Efecto Conjunto de la Longitud y Latitud en el Parámetro de Es

Superficie estimada mediante el spline bidimensional del EVGAM



0.7.6 Modelo 4: Scale en función a la profundidad y distancia a fallas

=== MODELO 3: Tendencia de profundidad y distancia a fallas en la escala ===

**** Parametric terms ****

logscale

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.34	0.01	-25.19	<2e-16



shape

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.16	0.01	-19.66	<2e-16

**** Smooth terms ****

logscale

	edf	max.df	Chi.sq	Pr(> t)
s(nearest_fault_dist,depth)	2.09	29	12.37	0.00398



0.7.7 Modelo 5: Scale en función del tiempo y magnitudes espaciales

=== MODELO 5: Tendencia temporal y espacial en la escala ===

** Parametric terms **

```


logscale
      Estimate Std. Error t value Pr(>|t|)
(Intercept)    0.32      0.03    9.5   <2e-16

shape
      Estimate Std. Error t value Pr(>|t|)
(Intercept)   -0.16      0.01  -22.79  <2e-16

** Smooth terms **

logscale
                                edf max.df Chi.sq Pr(>|t|)
s(time_days)                    7.54     9 334.88  <2e-16
s(nearest_fault_dist,depth):time_days 11.60    30 550.46  <2e-16

```



0.8 Selección y Comparación de Modelos

0.8.1 Criterios de Información y Verosimilitud Penalizada, para M0,M1,M2, M3,M4, M5

Table 1: Métricas de Selección y Ajuste para Modelos de Excedencia

Modelo	NLLH	AIC
M0: GPD Estacionario	4030.630	8065.260

Modelo	NLLH	AIC
M1: Tendencia Temporal Lineal (time_years)	3653.923	7313.846
M2: Tendencia Temporal No Lineal s(time_days)	3484.627	6989.517
M3: Efecto Espacial s(longitude, latitude)	3942.845	7932.623
M4: Efecto Espacial s(nearest_fault_dist, depth)	4025.604	8059.398
M5: Efecto Espacial y Temporal	3440.528	6922.568


0.8.2 Gráfico de Residuos Cruzados

Contrastamos la distribución de los residuos de Cox-Snell estandarizados frente a la distribución teórica exponencial para los cinco escenarios de excedencia

$$R_t = \frac{1}{\hat{\xi}_t} \log \left(1 + \hat{\xi}_t \frac{Y_t - u}{\hat{\sigma}_t} \right)$$


Si los residuos llegan a ser iid, la distribución llega a converger a una $\exp(1)$

ACF de los Residuos del Modelo M5



Forma del Error: Densidad de Residuos Estandarizados

Comparación de los 6 modelos frente a la referencia teórica Exp(1)



Modelos Evaluados M_Comb: Espacio-Temporal Físico

El modelo M\$ (Físico Geológico) es el mejor desde el punto de vista de los residuos. Al incluir la componente Espaciales (profundidad, distancia a fallas y además el factor cronológico), el modelo logra corregir parte de la distorsión en los residuos de magnitudes bajas/moderadas que los modelos temporales y el estacionario no pueden resolver