

Análisis de Valores Extremos en Datos Sísmicos

Daniel Lara

Table of contents

0.1	La Ley de Gutenberg-Richter (G-R)	1
0.2	Análisis de Extremos: Máximos por Bloques (GEV)	3
0.3	Análisis de Picos sobre el Umbral (POT)	4
0.4	Diagnóstico de Independencia y Declustering	5
0.4.1	Prueba de Independencia	5
0.4.2	Declustering	5
0.4.3	Diagnóstico del PP	6
0.5	Ajuste de Modelos de Excedencia (Procesos Puntuales / GPD)	6
0.5.1	Ajuste del Modelo GEV	6
0.5.2	Parámetros iniciales aleatorios	7
0.5.3	Con parámetros iniciales obtenidos del ajuste GEV previo:	8
0.5.4	Sin parámetros iniciales (modelo estándar GPD)	9
0.5.5	Ajuste del modelos en función del tiempo	10
0.6	Las r observaciones más grandes	10
0.7	Ajuste de parámetros con covariables	11
0.7.1	Preparación de datos	12
0.7.2	Modelo 0: Scale constante	12
0.7.3	Modelo 1: Tendencia temporal en la escala (σ)	13
0.7.4	Modelo 2: Estacionalidad o Periodicidad	15
0.8	Selección y Comparación de Modelos	17
0.8.1	Criterios de Información y Verosimilitud Penalizada, para M_0, M_1, M_2	17
0.8.2	Gráfico de Residuos Cruzados	17


0.1 La Ley de Gutenberg-Richter (G-R)

$$\log_{10} N(M) = a - bM$$

- $N(M)$ es el número acumulado de sismos con una magnitud mayor o igual a M .


- a es una constante que indica la tasa de sismicidad total de la región (un valor más alto significa mayor actividad sísmica general).
- b (conocido como el b -value) es una constante que describe la proporción entre sismos pequeños y grandes.

La de Gutenberg-Richter dicta que los datos deberían formar una línea recta perfecta.



A partir del valor mínimo de M_c (magnitud de completitud), la ley de G-R se aproxima a cumplirse, por ende, se debe trabajar con los datos por encima de este valor. Logrando que se garantice el supuesto de Poisson y será más práctica la implementación de los modelos.

0.2 Análisis de Extremos: Máximos por Bloques (GEV)





- **Gráfico de Probabilidades (P-Plot):** Podemos notar que las probabilidades reales se llegan a adaptar bien a las teóricas predichas por el modelo GEV.
- **Gráfico de Cuantiles (Q-Plot):** Las magnitudes van de 6 a 9, notamos que ajusta bien los valores más probables, sin embargo, en los extremos predichos ya se alejan de los datos reales y aumenta la incertidumbre.
- **Nivel de Retorno:** Nos muestra que los sismos entre 6 a 7.5 ocurren en periodos de 0.5 a 5 años; sin embargo, los sismos de magnitud 8, por ejemplo, ocurren cada 50 años.

Máxima de estabilidad por los hablado anteriormente, los datos se llegan a ajustar bien a un modelo GEV, por lo tanto, decimos que es la única distribución de los datos que es máxima estable Extremal Types Theorem y dado que el valor de $\xi_i > 0$, estamos en una GEV.....

0.3 Análisis de Picos sobre el Umbral (POT)

Gráfico de Vida Media Remanente para Sismos





Se toma un umbral entre 5 a 6, se tomará el valor de $\mu = 5$
 Se evidencia posiblemente que el parámetro $\xi > 0$ mostrando que las colas serán ligeras con un límite máximo

0.4 Diagnóstico de Independencia y Declustering

0.4.1 Prueba de Independencia

=== PRUEBA DE RACHAS PARA INDEPENDENCIA ===

Estadístico: -36.9075

p-valor: 0

0.4.2 Declustering


=== PRUEBA DE LJUNG-BOX (INDEPENDENCIA TEMPORAL) ===

Estadístico: 799.335

p-valor: 0

0.4.3 Diagnóstico del PP

post-Declustering







por qué se abren los IC? si ya eliminamos las replicas

0.5 Ajuste de Modelos de Excedencia (Procesos Puntuales / GPD)

0.5.1 Ajuste del Modelo GEV


loc	scale	shape
7.2658467	0.4306266	-0.1092916



0.5.2 Parámetros iniciales aleatorios

loc	scale	shape
8.2233691	0.2117894	-0.1541443

loc	scale	shape
0.057039567	0.011257730	0.007944734



El npp es correcto porque son una recopilación horaria por cada día del año


0.5.3 Con parámetros iniciales obtenidos del ajuste GEV previo:

```

      loc      scale      shape
8.2212478  0.2113051 -0.1544939

      loc      scale      shape
0.056868482  0.011218306  0.007937616

```



0.5.4 Sin parámetros iniciales (modelo estándar GPD)

```


scale      shape
0.5726232 -0.1122663

```

```

scale      shape
0.01347679 0.01454875

```



0.5.5 Ajuste del modelos en función del tiempo

0.5.5.1 Modelo lineal

0.6 Las r observaciones más grandes

Número de excedencias totales: 13670

Número de años: 122

Número de bloques (años): 56

Número de observaciones por bloque: 112

=== TABLA COMPARATIVA MODELOS r-largest ===

	Modelo	r	NLLH	AIC	Convergencia
r-largest	(r = 7)	7	-313.13	-620.26	0
r-largest	(r = 6)	6	-224.79	-443.57	0
r-largest	(r = 5)	5	-159.53	-313.06	0
r-largest	(r = 4)	4	-71.45	-136.91	0
r-largest	(r = 3)	3	-12.99	-19.97	0
r-largest	(r = 2)	2	17.54	41.07	0

Mejor modelo: r = 7 con AIC = -620.26

=== PARÁMETROS ESTIMADOS DEL MEJOR MODELO ===

[1] 7.3251 0.3856 -0.1798

Errores estándar:

[1] 0.0415 0.0220 0.0426

0.7 Ajuste de parámetros con covariables

EVGAM busca estimar los parámetros μ, σ, ξ por medio de combinaciones lineales con funciones llamadas B-splines que dependen de covariables (tiempo, magnitud, etc)

$$\mu(t) = \sum_{j=1}^k \beta_j b_j(t)$$

- $b_j(t)$ son las funciones base para estimar la función suave que describe la tendencia
- B_j parámetros libres que ajustan la Máxima Verosimilitud Penalizada (la forma como ajusta los parámetros)

Y trata de acercar los parámetros maximizando la log-verosimilitud penalizada

$$L_p(\beta) = l(\beta) - \frac{1}{2} \sum_j \lambda_j \beta^\top S_j \beta$$

- $l(\beta)$: Es la log-verosimilitud convencional (la bondad de ajuste).
- λ_j : Es el **parámetro de suavizado** (smoothing parameter). Es la perilla que controla qué tanto castigamos la falta de suavidad. (grande muy suave, pequeño curva muy flexible, tal vez sobreajustada)
- $\hat{S}_j$: Es una medida de la “curvatura” o rugosidad de la función. Si la línea sube y baja bruscamente, este término es muy grande.

Dentro de la formula para el uso del modelo EVGAM tenemos tres tipo de interacciones de las covariables

- $s(x) + s(y)$ Los efectos de x,y son independientes
- $te(x, y)$ existe interacción completa entre x,y
- $ti(x, y)$ cuantifica la interacción pura (se la complementa por ejemplo con $s(x) + s(y)$)

0.7.1 Preparación de datos

Se toma la diferencia con el mínimo para tener un tiempo inicial dentro de los datos que exceden el umbral

0.7.2 Modelo 0: Scale constante

=== MODELO 0: GPD ESTACIONARIO ===

**** Parametric terms ****

logscale


	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.34	0.01	-25.08	<2e-16

shape

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.15	0.01	-18.95	<2e-16

**** Smooth terms ****


GPD QQ Plot



por qué se abren los intervalos?

0.7.3 Modelo 1: Tendencia temporal en la escala (σ)

GPD QQ Plot



=== MODELO 1: Tendencia temporal en la escala ===

** Parametric terms **

```
logscale
      Estimate Std. Error t value Pr(>|t|)
(Intercept)  -0.34      0.01  -25.12  <2e-16
```


```
shape
      Estimate Std. Error t value Pr(>|t|)
(Intercept)  -0.15      0.01  -19.02  <2e-16
```

**** Smooth terms ****

```
logscale
      edf max.df Chi.sq Pr(>|t|)
s(dia_ano) 0.35      9   0.51   0.474
```

Lo que se puede rescatar aquí es el $s(\text{year_decimal})$ donde la escala σ_t fue cambiando a lo largo del tiempo de formas drásticas, se evidencia por los grados de libertad efectivos cercanos a 8 (miden la complejidad real de una curva suave ajustada).

El valor promedio de σ_t es cercano a 0, lo que podría indicar que las excedencias son más predecibles



Son los valores que aumentarán la varianza promedio a lo largo del tiempo, se los puede predecir y ver como irá cambiando la varianza\

$$\log(\sigma_t) = 0.35 + s(\text{year_decimal})$$

	Año	Sigma	Magnitud_Típica
726	363.5	2.040649	7.840649
727	364.0	2.040674	7.840674
728	364.5	2.040699	7.840699
729	365.0	2.040724	7.840724
730	365.5	2.040749	7.840749
731	366.0	2.040774	7.840774

0.7.4 Modelo 2: Estacionalidad o Periodicidad

**** Parametric terms ****

```
logscale
      Estimate Std. Error t value Pr(>|t|)
(Intercept)   -0.34      0.01  -25.08  <2e-16
```


```
shape
      Estimate Std. Error t value Pr(>|t|)
(Intercept)   -0.15      0.01  -18.95  <2e-16
```

**** Smooth terms ****

```
logscale
      edf max.df Chi.sq Pr(>|t|)
s(dia_ano) 0.04      8      0    0.994
```

Este modelo incorpora ciertas condiciones que dentro de los sismos puede ser de interés:

- **Continuidad del Valor:** $\hat{f}(x_{min}) = \hat{f}(x_{max})$ (La predicción al inicio del ciclo es idéntica a la del final). **riesgo transicione de forma suave y natural entre ciclos anuales.**
- **Continuidad de la Pendiente:** $\hat{f}'(x_{min}) = \hat{f}'(x_{max})$ (La tasa de cambio con la que cierra el año es la misma con la que abre el siguiente).
- **Continuidad de la Curvatura:** $\hat{f}''(x_{min}) = \hat{f}''(x_{max})$ (Garantiza que la transición visual y analítica sea perfectamente suave).



Aqui es donde se ve que se cumple las condiciones mencionadas.

	Dia_Ano	Sigma	Magnitud_Espera
20	286	0.7089837	5.708984
21	301	0.7089592	5.708959
22	316	0.7089311	5.708931
23	331	0.7088986	5.708899
24	346	0.7088624	5.708862
25	361	0.7088256	5.708826

0.8 Selección y Comparación de Modelos

0.8.1 Criterios de Información y Verosimilitud Penalizada, para M0,M1,M2

Table 1: Métricas de Selección y Ajuste para Modelos de Excedencia


Modelo	NLLH	AIC
M0: GPD Estacionario	4030.630	8065.260
M1: Tendencia Temporal s(year_decimal)	4030.196	8065.094
M2: Estacionalidad Cíclica s(dia_ano)	4030.612	8065.296

0.8.2 Gráfico de Residuos Cruzados

Contrastamos la distribución de los residuos de Cox-Snell estandarizados frente a la distribución teórica exponencial para los tres escenarios de excedencia

$$R_t = \frac{1}{\hat{\xi}_t} \log \left(1 + \hat{\xi}_t \frac{Y_t - u}{\hat{\sigma}_t} \right)$$

CCF de residuos cruzados (GPD)



El detalle dominante es el pico masivo en el rezago 0, donde la correlación cruzada es prácticamente 1.0. Esto significa que, a pesar de ser dos modelos distintos, están produciendo series de residuos casi idénticas.