


Análisis de Valores Extremos en Datos Sísmicos

Daniel Lara

Table of contents


0.1	Análisis de Extremos: Máximos por Bloques (GEV)	2
0.1.1	Ajuste del Modelo GEV	2
0.2	Análisis de Picos sobre el Umbral (POT)	4
0.3	Ajuste de Modelos de Excedencia (Procesos Puntuales / GPD)	5
0.3.1	Parámetros iniciales aleatorios	5
0.3.2	Con parámetros iniciales obtenidos del ajuste GEV previo:	6
0.3.3	Sin parámetros iniciales (modelo estándar GPD)	7
0.4	Diagnóstico de Independencia y Declustering	8
0.4.1	Prueba de Independencia	8
0.4.2	Diagnóstico del PP	9
0.5	Las r observaciones más grandes	9
0.6	Ajuste de parámetros con covariables	11
0.6.1	Preparación de datos	11
0.6.2	Modelo 0	12
0.6.3	Modelo 1: Tendencia temporal en la escala (σ)	13

0.1 Análisis de Extremos: Máximos por Bloques (GEV)



0.1.1 Ajuste del Modelo GEV

loc	scale	shape
7.2658467	0.4306266	-0.1092916





- **Gráfico de Probabilidades (P-Plot):** Podemos notar que las probabilidades reales se llegan a adaptar bien a las teóricas predichas por el modelo GEV.
- **Gráfico de Cuantiles (Q-Plot):** Las magnitudes van de 6 a 9, notamos que ajusta bien los valores más probables, sin embargo, en los extremos predichos ya se alejan de los datos reales y aumenta la incertidumbre.
- **Nivel de Retorno:** Nos muestra que los sismos entre 6 a 7.5 ocurren en periodos de 0.5 a 5 años; sin embargo, los sismos de magnitud 8, por ejemplo, ocurren cada 50 años.

Máxima de estabilidad por los hablado anteriormente, los datos se llegan a ajustar bien a un modelo GEV, por lo tanto, decimos que es la única distribución de los datos que es máxima estable Extremal Types Theorem y dado que el valor de $\xi_i < 0$, estamos en una GEV reversed Weibull

0.2 Análisis de Picos sobre el Umbral (POT)

Gráfico de Vida Media Remanente para Sismos





Se toma un umbral entre 5.5 a 6

Se evidencia posiblemente que el parámetro $\xi < 0$ mostrando que las colas serán ligeras con un límite máximo

0.3 Ajuste de Modelos de Excedencia (Procesos Puntuales / GPD)

0.3.1 Parámetros iniciales aleatorios

```


loc      scale      shape
7.831274 0.344794 -0.112154

```

```

loc      scale      shape
0.04317405 0.01777771 0.01454244

```



El npp es correcto porque son una recopilación horaria por cada día del año


0.3.2 Con parámetros iniciales obtenidos del ajuste GEV previo:

```

loc      scale      shape
7.8312785 0.3447975 -0.1121548

loc      scale      shape
0.04318605 0.01778548 0.01454822


```



0.3.3 Sin parámetros iniciales (modelo estándar GPD)

```
scale      shape
0.5726232 -0.1122663
```

```
scale      shape
0.01347679 0.01454875
```



0.4 Diagnóstico de Independencia y Declustering

0.4.1 Prueba de Independencia

=== PRUEBA DE RACHAS PARA INDEPENDENCIA ===


Estadístico: -145.6154

p-valor: 0


Número de eventos después del declustering: 2885

0.4.2 Diagnóstico del PP

Pre-Declustering



Post-Declustering



por qué se abren los IC? si ya eliminamos las replicas

0.5 Las r observaciones más grandes

Cómo definimos el ancho de cada bloque? Cómo definirlo en función del umbral (u)

Definiré el r como:

$$r \sim \frac{\# \text{ de sismos que superar el umbral } u}{\text{Número total de bloques (años?)}}$$

Número de excedencias totales: 3264

Número de años: 122

r óptimo calculado: 26

Número de bloques (años): 101

Número de observaciones por bloque: 26

=== TABLA COMPARATIVA MODELOS r-largest ===

	Modelo r	NLLH	AIC	Convergencia
r-largest (r = 7)	7	-552.13	-1098.26	0
r-largest (r = 6)	6	-393.27	-780.53	0
r-largest (r = 5)	5	-265.69	-525.37	0
r-largest (r = 4)	4	-127.53	-249.07	0
r-largest (r = 3)	3	-11.96	-17.92	0
r-largest (r = 2)	2	42.04	90.08	0

Mejor modelo: r = 7 con AIC = -1098.26

=== PARÁMETROS ESTIMADOS DEL MEJOR MODELO ===

[1] 7.3287 0.4226 -0.1115

Errores estándar:

[1] 0.0340 0.0175 0.0274

0.6 Ajuste de parámetros con covariables

EVGAM busca estimar los parámetros μ, σ, ξ por medio de combinaciones lineales con funciones llamadas B-splines que dependen de covariables (tiempo, magnitud, etc)

$$\mu(t) = \sum_{j=1}^k \beta_j b_j(t)$$

- $b_j(t)$ son las funciones base para estimar la función suave que describe la tendencia
- β_j parámetros libres que ajustan la Máxima Verosimilitud Penalizada (la forma como ajusta los parámetros)

Y trata de acercar los parámetros maximizando la log-verosimilitud penalizada

$$L_p(\beta) = l(\beta) - \frac{1}{2} \sum_j \lambda_j \beta^\top S_j \beta$$

- $l(\beta)$: Es la log-verosimilitud convencional (la bondad de ajuste).
- λ_j : Es el **parámetro de suavizado** (smoothing parameter). Es la perilla que controla qué tanto castigamos la falta de suavidad. (grande muy suave, pequeño curva muy flexible, tal vez sobreajustada)
- $\sum_j S_j$: Es una medida de la “curvatura” o rugosidad de la función. Si la línea sube y baja bruscamente, este término es muy grande.

Dentro de la formula para el uso del modelo EVGAM tenemos tres tipo de interacciones de las covariables

- $s(x) + s(y)$ Los efectos de x,y son independientes
- $te(x, y)$ existe interacción completa entre x,y
- $ti(x, y)$ cuantifica la interacción pura (se la complementa por ejemplo con $s(x) + s(y)$)

0.6.1 Preparación de datos

Se toma la diferencia con el mínimo para tener un tiempo inicial dentro de los datos que exceden el umbral

0.6.2 Modelo 0

=== MODELO 0: GPD ESTACIONARIO ===

**** Parametric terms ****

logscale


	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.56	0.02	-23.69	<2e-16

shape

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.11	0.01	-7.71	6.05e-15

**** Smooth terms ****


GPD QQ Plot



por qué se abren los intervalos?

0.6.3 Modelo 1: Tendencia temporal en la escala (σ)

GPD QQ Plot



=== MODELO 1: Tendencia temporal en la escala ===

**** Parametric terms ****

logscale

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.57	0.02	-24.75	<2e-16

shape

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.11	0.01	-7.69	7.19e-15


**** Smooth terms ****

logscale

	edf	max.df	Chi.sq	Pr(> t)
s(year_decimal)	4.99	9	53.28	4.77e-10

Lo que se puede rescatar aquí es el $s(\text{year_decimal})$ donde la escala σ_t fue cambiando a lo largo del tiempo de formas drásticas, se evidencia por los grados de libertad efectivos cercanos a 5 (miden la complejidad real de una curva suave ajustada).

El valor promedio de σ_t es cercano a 0, lo que podría indicar que las excedencias son más predecibles



Son los valores que aumentarán la varianza promedio a lo largo del tiempo, se los puede predecir y ver como irá cambiando la varianza\

$$\log(\sigma_t) = -0.57 + s(\text{year_decimal})$$

	Año	Sigma	Magnitud_Típica
239	2023.055	1.751996	7.551996
240	2023.555	1.753250	7.553250
241	2024.055	1.754501	7.554501
242	2024.555	1.755749	7.555749
243	2025.055	1.756997	7.556997
244	2025.555	1.758245	7.558245