

Análisis de Valores Extremos en Datos Sísmicos

Daniel Lara

Table of contents


0.1	La Ley de Gutenberg-Richter (G-R)	1
0.2	Análisis de Picos sobre el Umbral (POT)	2
0.3	Diagnóstico de Independencia y Declustering	3
0.3.1	Prueba de Independencia	3
0.3.2	Declustering	4
0.3.3	Diagnostico del PP	4
0.4	Ajuste de parámetros con covariables	4
0.4.1	Modelo 0: Scale constante	5
0.4.2	Modelo 1: Scale en función (lineal) del tiempo	6
0.4.3	Modelo 2: Scale en función del tiempo con splines cúbicos	7
0.4.4	Modelo 3: Scale en función de Longitud y Latitud	8
0.4.5	Modelo 4: Scale en función a la profundidad y distancia a fallas	10
0.4.6	Modelo 5: Scale en función del tiempo y magnitudes espaciales	11
0.4.7	Modelo 6: Sismos según su tipo: Ejemplo Momento Equivalente	12
0.5	Selección y Comparación de Modelos	14
0.5.1	Criterios de Información y Verosimilitud Penalizada, para M0,M1,M2, M3,M4, M5 y M6	14
0.5.2	Gráfico de Residuos Cruzados	15

0.1 La Ley de Gutenberg-Richter (G-R)

$$\log_{10}N(M) = a - bM$$

- $N(M)$ es el número acumulado de sismos con una magnitud mayor o igual a M .
- a es una constante que indica la tasa de sismicidad total de la región (un valor más alto significa mayor actividad sísmica general).
- b (conocido como el *b-value*) es una constante que describe la proporción entre sismos pequeños y grandes.


La de Gutenberg-Richter dicta que los datos deberían formar una línea recta perfecta.




A partir del valor mínimo de M_c (magnitud de completitud), la ley de G-R se aproxima a cumplirse, por ende, se debe trabajar con los datos por encima de de este valor. Logrando que se garantice el supuesto de Poisson y será más práctica la implementación de los modelos.

0.2 Análisis de Picos sobre el Umbral (POT)

Gráfico de Vida Media Remanente para Sismos





Se toma un umbral entre 5 a 6, se tomará el valor de $\mu = 5$

Se evidencia posiblemente que el parámetro $\xi < 0$ mostrando que las colas serán ligeras con un límite máximo.

0.3 Diagnóstico de Independencia y Declustering

0.3.1 Prueba de Independencia

=== PRUEBA DE RACHAS PARA INDEPENDENCIA ===

Estadístico: -36.9075

p-valor: 0


0.3.2 Declustering

=== PRUEBA DE LJUNG-BOX (INDEPENDENCIA TEMPORAL) ===

Estadístico: 799.335

p-valor: 0

0.3.3 Diagnóstico del PP



0.4 Ajuste de parámetros con covariables

EVGAM busca estimar los parámetros μ, σ, ξ por medio de combinaciones lineales con funciones llamadas B-splines que dependen de covariables (tiempo, magnitud, etc)

$$\mu(t) = \sum_{j=1}^k \beta_j b_j(t)$$

- $b_j(t)$ son las funciones base para estimar la función suave que describe la tendencia
- B_j parámetros libres que ajustan la Máxima Verosimilitud Penalizada (la forma como ajusta los parámetros)

Existen distintas bases b_k según el **bs** elegido:

1. **bs=“cr”**, cubic regression splines: Aquí cada b_k es un polinomio cúbico con cada pico en cada nodo (punto de interés) dentro de un rango. POR RANGOS GENERARÁ LOS POLINOMIOS

2. **bs=“tp”** Thin Plate Regression Splines: Maneja interacciones de múltiples variables de forma isotrópica (suaviza el espacio por igual en todas las direcciones)

K: Límite superior de complejidad

$$b_k(x) = r^2 \log(r)$$

$$r = \|x - x_k\|$$

3. **bs=“cs”** Shrinkage: Similar a cr, con la diferencia que puede otorgar pesos a las variables dependiendo de su importancia.

Dentro de la formula para el uso del modelo EVGAM tenemos tres tipo de interacciones de las covariables

- $s(x) + s(y)$ Los efectos de x,y son independientes
- $te(x, y)$ existe interacción completa entre x,y
- $ti(x, y)$ cuantifica la interacción pura (se la complementa por ejemplo con $s(x) + s(y)$)

0.4.1 Modelo 0: Scale constante

=== MODELO 0: GPD ESTACIONARIO ===

**** Parametric terms ****

logscale


	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.34	0.01	-25.08	<2e-16

shape

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.15	0.01	-18.95	<2e-16


**** Smooth terms ****

GPD QQ Plot



0.4.2 Modelo 1: Scale en función (lineal) del tiempo

GPD QQ Plot



=== MODELO 2: Tendencia temporal en la escala ===

**** Parametric terms ****

logscale

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.33	0.03	10.79	<2e-16
time_years	-0.01	0.00	-23.95	<2e-16


shape

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.14	0.01	-21.29	<2e-16

** Smooth terms **

0.4.3 Modelo 2: Scale en función del tiempo con splines cúbicos

GPD QQ Plot



=== MODELO 2: Tendencia temporal en la escala ===

** Parametric terms **

logscale

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.42	0.01	-32.12	<2e-16

shape

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.15	0.01	-20.89	<2e-16


**** Smooth terms ****

logscale

	edf	max.df	Chi.sq	Pr(> t)
s(time_days)	8.13	9	751.99	<2e-16

Lo que se puede rescatar aquí es el $s(\text{year_decimal})$ donde la escala σ_t fue cambiando a lo largo del tiempo de formas drásticas, se evidencia por los grados de libertad efectivos cercanos a 8 (miden la complejidad real de una curva suave ajustada).

El valor promedio de σ_t es cercano a 0, lo que podría indicar que las excedencias son más predecibles



Son los valores que aumentarán la varianza promedio a lo largo del tiempo, se los puede predecir y ver como irá cambiando la varianza.

$$\log(\sigma_t) = -0.42 + s(\text{year_decimal})$$

0.4.4 Modelo 3: Scale en función de Longitud y Latitud

**** Parametric terms ****

logscale

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.34	0.01	-24.74	<2e-16

shape


	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.17	0.01	-20.98	<2e-16

** Smooth terms **

logscale


	edf	max.df	Chi.sq	Pr(> t)
s(longitude,latitude)	21.47	29	158.92	<2e-16

GPD QQ Plot



Efecto Conjunto de la Longitud y Latitud en el Parámetro de Es

Superficie estimada mediante el spline bidimensional del EVGAM



0.4.5 Modelo 4: Scale en función a la profundidad y distancia a fallas

=== MODELO 4: Tendencia de profundidad y distancia a fallas en la escala ===

**** Parametric terms ****

logscale

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.34	0.01	-25.19	<2e-16



shape

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.16	0.01	-19.66	<2e-16

**** Smooth terms ****

logscale

	edf	max.df	Chi.sq	Pr(> t)
s(nearest_fault_dist,depth)	2.09	29	12.37	0.00398



0.4.6 Modelo 5: Scale en función del tiempo y magnitudes espaciales

=== MODELO 5: Tendencia temporal y espacial en la escala ===

**** Parametric terms ****


```
logscale
      Estimate Std. Error t value Pr(>|t|)
(Intercept)    0.32      0.03    9.5   <2e-16
```

```
shape
      Estimate Std. Error t value Pr(>|t|)
(Intercept)   -0.16      0.01  -22.79  <2e-16
```

**** Smooth terms ****

```
logscale
                                edf max.df Chi.sq Pr(>|t|)
s(time_days)                    7.54     9 334.88  <2e-16
s(nearest_fault_dist,depth):time_days 11.60    30 550.46  <2e-16
```

GPD QQ Plot



0.4.7 Modelo 6: Sismos según su tipo: Ejemplo Momento Equivalente


Hay distintos tipos de magnitudes observadas: Magnitudes de Momento (mw), Local o Richter (ml), Ondas de cuerpo (mb) y Superficie (ms), Duración (md) y otras. Notemos lo siguiente:

mw	mb	mwc	mww	mwb	ms	ml
2776	1761	1612	1098	430	261	45
mwr	mB	m	mh	mwp	lg	md

41	4	2	2	2	1	1
Md	Ml	ml(texnet)				
1	1	1				

Veamos si los tipos de magnitudes pueden meter ruido o sesgos debido a los efectos de saturación de escalas como mb o ml, con el objetivo que mostrar que las magnitudes mb se ve una saturación instrumental, es decir, pueden ser mayores a lo que realmente fueron.

Comparación de Densidades (Excedencias)



Se puede notar los sismos de tipo mb ya son irreconocibles cuando superan un cierto umbral. Por eso se recomienda trabajar para valores extremos con los sismos que tengan magnitudes tipo Mw, porque muestran el efecto real.

=== MODELO 6: Tendencia de profundidad y distancia a fallas en la escala ===

**** Parametric terms ****

logscale

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.16	0.01	-10.91	<2e-16

shape


	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.21	0.01	-39.04	<2e-16

**** Smooth terms ****

logscale

```
edf max.df Chi.sq Pr(>|t|)
s(nearest_fault_dist,depth) 2.66      29  10.87  0.0054
```

GPD QQ Plot



0.5 Selección y Comparación de Modelos

0.5.1 Criterios de Información y Verosimilitud Penalizada, para M0,M1,M2, M3,M4, M5 y M6

Table 1: Métricas de Selección y Ajuste para Modelos de Excedencia

Modelo	NLLH	AIC
M0: GPD Estacionario	4030.630	8065.260
M1: Tendencia Temporal Lineal (time_years)	3653.923	7313.846
M2: Tendencia Temporal No Lineal s(time_days)	3484.627	6989.517
M3: Efecto Espacial s(longitude, latitude)	3942.845	7932.623
M4: Efecto Espacial s(nearest_fault_dist, depth)	4025.604	8059.398
M5: Efecto Espacial y Temporal	3440.528	6922.568
M6: Efecto Espacial s(nearest_fault_dist, depth), Magnitudes Mw	3457.177	6923.672

0.5.2 Gráfico de Residuos Cruzados

Contrastamos la distribución de los residuos de Cox-Snell estandarizados frente a la distribución teórica exponencial para los cinco escenarios de excedencia.

$$R_t = \frac{1}{\hat{\xi}_t} \log \left(1 + \hat{\xi}_t \frac{Y_t - u}{\hat{\sigma}_t} \right)$$

Si los residuos llegan a ser iid, la distribución llega a converger a una $\exp(1)$.

0.5.2.1 Demostración:

Se sabe que: $Y = X - u \sim GDP(\sigma, \xi)$, y $U = F_Y(y) = 1 - (1 + \frac{\xi y}{\sigma})^{-\frac{1}{\xi}} \sim Unif(0, 1)$.

Definimos: $R = -\log(1 - U)$


$$\begin{aligned} P(R \leq r) &= P(-\log(1 - U) \leq r) \\ &= P(1 - U \geq e^{-r}) \\ &= P(U \leq 1 - e^{-r}) \\ &= 1 - e^{-r} \end{aligned}$$

Así, notemos que:

$$R = -\log(1 - U) = \frac{1}{\hat{\xi}} \log \left(1 + \hat{\xi} \frac{Y - u}{\hat{\sigma}} \right) \sim \text{Exp}(1)$$

Si los residuos llegan a ser iid, la distribución llega a converger a una $\exp(1)$.


ACF de los Residuos del Modelo M5



0.5.2.2 Gráfico: Residuos vs Exp(1)

Forma del Error: Densidad de Residuos Estandarizados

Comparación de los 7 modelos frente a la referencia teórica Exp(1)



Modelos Evaluados M5: Espacio-Temporal Físico

El modelo M5 es el mejor desde el punto de vista de los residuos. Al incluir la componente Espaciales(profundidad, distancia a fallas) y además el factor temporal, el modelo logra corregir parte de la distorsión en los residuos de magnitudes bajas/moderadas que los modelos temporales y el estacionario no pueden resolver.