

Sesión 6: Aleatoriedad espacial completa y pruebas Monte Carlo

Envoltentes de simulación con R y spatstat

Yandira Cuvero

Procesos puntuales para estudiantes de matemática

De la sesión 5 a la sesión 6

En la sesión anterior estudiamos funciones resumen:

$$F(r), \quad G(r), \quad J(r), \quad K(r), \quad L(r).$$

Bajo un proceso de Poisson homogéneo en el plano:

$$K(r) = \pi r^2, \quad L(r) = r.$$

Pregunta de esta sesión

Cuando observamos una curva empírica, ¿cómo decidimos si su desviación respecto al modelo Poisson es estadísticamente relevante?

Aleatoriedad espacial completa

La aleatoriedad espacial completa, o *complete spatial randomness*, corresponde al modelo:

$$X \sim \text{Poisson homogéneo}(\lambda), \quad \lambda > 0.$$

Esto significa:

- 1 El número de puntos en una región depende solamente de su área.
- 2 Los conteos en regiones disjuntas son independientes.
- 3 Condicionalmente a $N(W) = n$, los puntos son independientes y uniformes en W .

Idea central

Bajo CSR no hay estructura espacial más allá de la variación aleatoria.

Hipótesis estadística

Para un patrón observado $\mathbf{x} = \{x_1, \dots, x_n\}$ en una ventana W , la hipótesis nula es:

$$H_0 : X \sim \text{Poisson homogéneo en } W.$$

Una alternativa general puede ser:

$$H_1 : X \text{ no sigue un proceso de Poisson homogéneo.}$$

Pero esta alternativa es amplia. Puede incluir:

- intensidad no constante,
- agrupamiento,
- inhibición,
- anisotropía,
- efectos de borde o errores de observación.

Por qué no basta mirar un gráfico

Suponga que calculamos $\hat{K}(r)$ y observamos que:

$$\hat{K}(r) > \pi r^2.$$

Esto sugiere agregación, pero no implica automáticamente que rechazamos CSR.

Problema

Incluso bajo CSR, una realización aleatoria puede producir curvas por encima o por debajo del valor teórico.

Necesitamos comparar la curva observada con la variabilidad esperada bajo H_0 .

Principio de las pruebas Monte Carlo

La idea es reemplazar un cálculo analítico difícil por simulación bajo H_0 .

Procedimiento general:

- 1 Observar el patrón real X_{obs} .
- 2 Elegir una estadística $T(X)$, por ejemplo $\hat{K}(r)$.
- 3 Simular $X_1, \dots, X_m$ bajo H_0 .
- 4 Calcular $T(X_1), \dots, T(X_m)$.
- 5 Comparar $T(X_{obs})$ con la distribución simulada.

Lectura estadística

Si el patrón observado es extremo respecto a los simulados, hay evidencia contra H_0 .

Simular bajo CSR: dos enfoques

Hay dos formas comunes de simular bajo la hipótesis de Poisson homogéneo.

Poisson no condicionado

Se estima:

$$\hat{\lambda} = \frac{n}{|W|}.$$

Luego se simula:

$$N(W) \sim \text{Poisson}(\hat{\lambda}|W|).$$

El número de puntos cambia en cada simulación.

Binomial condicionado

Se fija:

$$N(W) = n.$$

Luego se simulan n puntos independientes uniformes en W . El número de puntos se mantiene igual al observado.

Cuál enfoque usar

Si interesa probar el proceso Poisson completo

Puede usarse el modelo Poisson no condicionado.

$N(W)$ también es aleatorio.

Si interesa condicionar al número observado de puntos

Puede usarse el modelo binomial condicionado.

$N(W) = n$ se mantiene fijo.

En la práctica, muchos análisis exploratorios usan simulaciones condicionadas a n porque separan la estructura espacial de la variabilidad en el número total de eventos.

Patrón observado simulado en R

Primero generamos un patrón que actuará como nuestro patrón observado.

```
library(spatstat)

set.seed(123)
X <- rpoispp(lambda = 100)

plot(X, main = "Patrón observado")
summary(X)
```

En un análisis real, X vendría de datos observados:

```
X <- ppp(x = datos$x,
        y = datos$y,
        window = W)
```

Simulaciones bajo CSR

Podemos simular varios patrones Poisson homogéneos con la misma intensidad estimada.

```
lambda_hat <- intensity(X)

Y1 <- rpoispp(lambda_hat, win = Window(X))
Y2 <- rpoispp(lambda_hat, win = Window(X))
Y3 <- rpoispp(lambda_hat, win = Window(X))

par(mfrow = c(1, 3))
plot(Y1, main = "Simulacion 1")
plot(Y2, main = "Simulacion 2")
plot(Y3, main = "Simulacion 3")
par(mfrow = c(1, 1))
```

Una estadística funcional

En patrones puntuales, la estadística no siempre es un número.

Por ejemplo, la función K genera una curva:

$$r \longmapsto \hat{K}(r).$$

Por eso, en lugar de comparar un solo valor, comparamos una función completa.

Estadística funcional

Una función resumen estimada puede verse como una estadística dependiente de r :

$$T_r(X) = \hat{K}_X(r), \quad r \geq 0.$$

Envolventes de simulación

Para cada distancia r , simulamos muchas curvas bajo H_0 :

$$\hat{K}_1(r), \dots, \hat{K}_m(r).$$

Luego calculamos límites inferior y superior:

$$L_m(r) = \min_{j=1, \dots, m} \hat{K}_j(r), \quad U_m(r) = \max_{j=1, \dots, m} \hat{K}_j(r).$$

Interpretación gráfica

Si la curva observada queda fuera de la envolvente, el patrón observado es más extremo que las simulaciones bajo CSR.

Envolvente para la función K

En spatstat, la función principal es `envelope()`.

```
E_K <- envelope(X,  
               fun = Kest,  
               nsim = 99)  
  
plot(E_K,  
     main = "Envolvente Monte Carlo para K")
```

Lectura básica:

- curva negra: función observada,
- región sombreada o bandas: comportamiento esperado bajo CSR,
- curva teórica: valor esperado bajo el modelo nulo.

Envolvente para la función L

La función L suele ser más fácil de interpretar que K :

$$L(r) = \sqrt{\frac{K(r)}{\pi}}.$$

Bajo CSR:

$$L(r) - r = 0.$$

```
E_L <- envelope(X,  
               fun = Lest,  
               nsim = 99)  
  
plot(E_L,  
     main = "Envolvente Monte Carlo para L")
```

Interpretación con $L(r) - r$

Muchas veces se grafica:

$$\hat{L}(r) - r.$$

Bajo CSR:

$$\hat{L}(r) - r \approx 0.$$

Agregación

$$\hat{L}(r) - r > 0.$$

Hay más vecinos cercanos de lo esperado.

Regularidad

$$\hat{L}(r) - r < 0.$$

Hay menos vecinos cercanos de lo esperado.

CSR

$$\hat{L}(r) - r \approx 0.$$

No hay señal clara de interacción.

Graficar $L(r) - r$ en R

La opción `.-r` permite centrar la función alrededor del valor teórico bajo CSR.

```
L_X <- Lest(X)

plot(L_X,
     . - r ~ r,
     main = "Funcion L centrada: L(r) - r",
     ylab = "L(r) - r")
```

También puede usarse con envolventes:

```
E_L <- envelope(X, Lest, nsim = 99)
plot(E_L, . - r ~ r,
     main = "Envolvente para L(r) - r")
```

Envolventes puntuales

Una envolvente puntual controla la variabilidad para cada valor fijo de r .

Para cada r se calculan, por ejemplo, cuantiles simulados:

$$q_{\alpha/2}(r), \quad q_{1-\alpha/2}(r).$$

Entonces la curva observada se compara punto por punto.

Advertencia

Si miramos muchos valores de r , aumenta la probabilidad de que la curva salga de la banda en algún punto solamente por azar.

Envolventes globales

Una envolvente global evalúa si la curva completa es extrema.

En lugar de preguntar:

¿es extrema en este r ?

se pregunta:

¿es extrema como función de r ?

Ventaja

Las envolventes globales son más adecuadas para pruebas formales, porque consideran el problema de comparar muchas distancias simultáneamente.

Envolvente global en spatstat

Para una prueba más formal, podemos solicitar una envolvente global.

```
E_global <- envelope(X,  
                    fun = Lest,  
                    nsim = 99,  
                    global = TRUE)  
  
plot(E_global,  
     . - r ~ r,  
     main = "Envolvente global para L(r) - r")
```

La interpretación es más estricta que en una envolvente meramente puntual.

Valor- p Monte Carlo

Si usamos una estadística escalar $T(X)$, el valor- p Monte Carlo puede escribirse como:

$$p = \frac{1 + \#\{j : T(X_j) \geq T(X_{obs})\}}{m + 1}.$$

El $+1$ evita valores- p iguales a cero cuando se usa un número finito de simulaciones.

Resolución de la prueba

Con $m = 99$ simulaciones, el menor valor- p posible es:

$$\frac{1}{100} = 0.01.$$

Cuántas simulaciones usar

El número de simulaciones afecta la estabilidad de la envolvente.

Valores comunes:

$$nsim = 39, \quad 99, \quad 199, \quad 999.$$

- Para una demostración en clase: 39 o 99 puede ser suficiente.
- Para un reporte o artículo: conviene usar más simulaciones.
- Más simulaciones implican mayor costo computacional.

Regla práctica

Para una prueba al 5 %, $nsim = 99$ es una elección pedagógica natural, pero no necesariamente suficiente para investigación final.

Ejemplo: patrón compatible con CSR

Simulamos un patrón Poisson homogéneo y construimos su envolvente.

```
set.seed(321)
X_pois <- rpoispp(100)

E_pois <- envelope(X_pois,
                   Lest,
                   nsim = 99,
                   global = TRUE)

plot(E_pois, . ~ r ~ r,
     main = "Patron Poisson: L(r) - r")
```

Esperamos que la curva observada permanezca dentro de las bandas con frecuencia alta si el modelo nulo es verdadero.

Ejemplo: patrón agrupado

Ahora simulamos un proceso de Thomas, que produce agrupamiento.

```
set.seed(321)
X_cluster <- rThomas(kappa = 10,
                    scale = 0.04,
                    mu = 10)

plot(X_cluster,
     main = "Proceso de Thomas")

E_cluster <- envelope(X_cluster,
                    Lest,
                    nsim = 99,
                    global = TRUE)

plot(E_cluster, . - r ~ r,
     main = "Agrupamiento:  $L(r) - r$ ")
```

Interpretación del patrón agrupado

Para un patrón agrupado, usualmente observamos:

$$\hat{L}(r) - r > 0$$

para distancias pequeñas o intermedias.

Esto significa que hay más pares de puntos cercanos de lo esperado bajo CSR.

Lectura espacial

Un punto observado aumenta la probabilidad de encontrar otros puntos cerca.

Sin embargo, debemos verificar si esto se debe a interacción real o a una intensidad espacial no homogénea.

Ejemplo: patrón regular

Simulamos un patrón inhibitorio usando un proceso de inhibición secuencial simple.

```
set.seed(321)
X_regular <- rSSI(r = 0.06, n = 100)

plot(X_regular,
     main = "Patron regular")

E_regular <- envelope(X_regular,
                     Lest,
                     nsim = 99,
                     global = TRUE)

plot(E_regular, . - r ~ r,
     main = "Regularidad: L(r) - r")
```

Interpretación del patrón regular

Para un patrón regular, usualmente observamos:

$$\hat{L}(r) - r < 0$$

para distancias pequeñas.

Esto significa que hay menos pares de puntos cercanos de lo esperado bajo CSR.

Lectura espacial

Un punto observado reduce la probabilidad de encontrar otro punto muy cerca.

Este comportamiento aparece, por ejemplo, en árboles con competencia espacial o diseños experimentales con separación mínima.

Cuidado: inhomogeneidad vs interacción

Un problema central es distinguir entre:

Inhomogeneidad

La intensidad cambia en el espacio:

$$\lambda(u) \neq \lambda.$$

Los puntos se concentran donde $\lambda(u)$ es mayor.

Interacción

La presencia de un punto modifica la ocurrencia de otros puntos cercanos.

$$X_i \text{ afecta a } X_j.$$

Un patrón no homogéneo puede parecer agrupado aunque sea Poisson.

Ejemplo: Poisson no homogéneo

Simulamos un proceso Poisson con intensidad variable:

$$\lambda(x, y) = 200 \exp(-3x).$$

```
set.seed(123)
lambda_fun <- function(x, y) 200 * exp(-3 * x)

X_inhom <- rpoispp(lambda_fun)
plot(X_inhom,
     main = "Poisson no homogeneo")

E_wrong <- envelope(X_inhom,
                    Lest,
                    nsim = 99,
                    global = TRUE)

plot(E_wrong, . - r ~ r)
```

Una prueba contra CSR puede rechazar, pero la causa puede ser la intensidad no constante.

Hipótesis nula inhomogénea

Cuando la intensidad no es constante, una hipótesis más apropiada puede ser:

$$H_0 : X \sim \text{Poisson no homogéneo con intensidad } \lambda(u).$$

Ahora la independencia se mantiene, pero el riesgo espacial varía.

Cambio conceptual

Ya no preguntamos si el patrón es homogéneo. Preguntamos si, después de explicar la intensidad espacial, queda evidencia de interacción.

Funciones resumen inhomogéneas

spatstat contiene versiones inhomogéneas de algunas funciones resumen.

```
# Estimar intensidad
lambda_est <- density(X_inhom)

# Funcion K inhomogenea
K_inhom <- Kinhom(X_inhom,
                  lambda = lambda_est)

plot(K_inhom,
      main = "Funcion K inhomogenea")
```

La idea es corregir el efecto de la variación espacial de la intensidad.

Envolvente bajo modelo ajustado

Una alternativa es ajustar un modelo y simular desde ese modelo.

```
# Covariable espacial simple: coordenada x
Z <- as.im(function(x, y) x, W = Window(X_inhom))

fit <- ppm(X_inhom ~ Z)
summary(fit)

E_fit <- envelope(fit,
                  fun = Kinhom,
                  nsim = 99,
                  global = TRUE)

plot(E_fit,
     main = "Envolvente bajo modelo ajustado")
```

Esto conecta las pruebas Monte Carlo con diagnóstico de modelos.

Corrección de borde

Las funciones resumen cuentan vecinos dentro de distancias r .

Si un punto está cerca del borde de W , parte de su vecindad cae fuera de la ventana observada.

Problema de borde

Sin corrección, podemos subestimar el número de vecinos cercanos para puntos próximos al borde.

Por eso funciones como `Kest()` usan correcciones, por ejemplo:

- border,
- isotropic,
- translation,
- Ripley.

Elegir corrección de borde en R

Podemos especificar la corrección deseada.

```
K_iso <- Kest(X, correction = "isotropic")
K_trans <- Kest(X, correction = "translation")
K_border <- Kest(X, correction = "border")

plot(K_iso, main = "Correccion isotropica")
plot(K_trans, main = "Correccion por traslacion")
plot(K_border, main = "Correccion de borde")
```

En docencia, lo importante es que los estudiantes entiendan por qué la corrección es necesaria antes de comparar curvas.

Una prueba no reemplaza el razonamiento

Las envolventes Monte Carlo son herramientas útiles, pero no deben interpretarse mecánicamente.

Preguntas importantes:

- 1 ¿La ventana W está bien definida?
- 2 ¿Hay covariables espaciales omitidas?
- 3 ¿La intensidad puede ser no homogénea?
- 4 ¿La escala r tiene sentido para el fenómeno?
- 5 ¿El patrón observado tiene errores de localización?

Principio

La inferencia espacial combina modelo probabilístico, simulación y conocimiento del fenómeno.

Bajo CSR:

$$X \sim \text{Poisson homogéneo}(\lambda).$$

Para la función K :

$$K(r) = \pi r^2, \quad L(r) = r.$$

Una envolvente Monte Carlo aproxima la distribución de una estadística funcional bajo H_0 :

$$\hat{K}_1(r), \dots, \hat{K}_m(r).$$

La curva observada se compara con lo que sería esperable si H_0 fuera verdadero.

Funciones principales en spatstat:

Objetivo	Función en R
Simular Poisson homogéneo	<code>rpoispp()</code>
Simular patrón agrupado	<code>rThomas()</code>
Simular patrón regular	<code>rSSI()</code>
Calcular función K	<code>Kest()</code>
Calcular función L	<code>Lest()</code>
Construir envolventes	<code>envelope()</code>
Modelo Poisson ajustado	<code>ppm()</code>
Función K inhomogénea	<code>Kinhom()</code>

Laboratorio propuesto

Parte 1. Simule tres patrones:

```
X1 <- rpoispp(100)
X2 <- rThomas(kappa = 10, scale = 0.04, mu = 10)
X3 <- rSSI(r = 0.06, n = 100)
```

Parte 2. Para cada patrón:

```
plot(X1)
plot(Lest(X1), . ~ r ~ r)
envelope(X1, Lest, nsim = 99, global = TRUE)
```

Parte 3. Compare los resultados y clasifique cada patrón como compatible con CSR, agrupado o regular.

Preguntas para discusión

- 1 ¿Por qué una curva fuera de la envolvente sugiere evidencia contra H_0 ?
- 2 ¿Qué diferencia hay entre una envolvente puntual y una envolvente global?
- 3 ¿Por qué un patrón Poisson no homogéneo puede parecer agrupado?
- 4 ¿Qué papel juega la escala r en la interpretación?
- 5 ¿Por qué debemos tener cuidado con el borde de la ventana?

Considere un patrón puntual observado X en una ventana W .

- 1 Formule explícitamente la hipótesis H_0 de CSR.
- 2 Calcule $\hat{L}(r) - r$ usando spatstat.
- 3 Construya una envolvente global con 99 simulaciones.
- 4 Interprete el resultado en términos de agregación, regularidad o compatibilidad con CSR.
- 5 Explique si el rechazo de CSR necesariamente implica interacción espacial.

Idea principal

Las envolventes Monte Carlo permiten convertir una comparación visual en una comparación estadística basada en simulación bajo un modelo nulo.

En la siguiente sesión estudiaremos con más detalle procesos con interacción:

Poisson $\longrightarrow$ agrupamiento e inhibición.